

Aprendizaje por Refuerzo

Fundamentos y Aplicaciones

Clase 2 — Políticas, Funciones de Valor, Ecuación de Bellman
y el Problema del Bandido Multibrazo

Dr. Darío Ezequiel Díaz

12 de mayo de 2026

Facultad de Ingeniería — Posgrados
Universidad Austral

Hoja de ruta del encuentro

Recapitulación de la Clase 1 y puente conceptual

Políticas: el lenguaje de la decisión

Funciones de valor: la métrica del desempeño

La ecuación de Bellman y el operador de Bellman

El problema del bandido multibrazo

Trabajo práctico, anticipo y bibliografía

Recapitulación de la Clase 1 y puente conceptual

Lo que dejamos sentado la semana pasada

La quintupla del MDP

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$$

- $\mathcal{S}$: espacio de estados.
- $\mathcal{A}$: espacio de acciones.
- $P(s' | s, a)$: dinámica de transición.
- $R(s, a)$: recompensa esperada inmediata.
- $\gamma \in [0, 1)$: factor de descuento.

Construimos GridWorld desde cero, recorrimos CartPole con una política aleatoria y estimamos $\mathbb{E}[G_0]$ vía Monte Carlo ingenuo, evidenciando la **varianza** intrínseca de las trayectorias.

Propiedad de Markov

$\mathbb{P}(S_{t+1} | S_t, A_t)$ no depende del pasado anterior a S_t . El *estado* comprime la historia relevante.

Retorno

$$G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

Las preguntas que quedaron abiertas


La Clase 1 cerró con cuatro preguntas que estructuran el encuentro de hoy:

1. ¿Cómo se formaliza una **política** y cuáles son sus variantes?
2. ¿Cómo se define rigurosamente la **función de valor** de una política?
3. ¿Bajo qué argumento matemático la **ecuación de Bellman** admite una solución única, y cómo la calculamos?
4. Cuando el espacio de estados se reduce a uno solo, ¿cómo se gestiona el dilema **exploración–explotación**? Aquí emerge el **bandido multibrazo**.

Propósito del encuentro

Adquirir el aparato conceptual y los teoremas que sostienen todo algoritmo de RL que veremos a partir de la Clase 3.

Mapa conceptual de hoy



Recorreremos el flujo en ese orden: política $\rightarrow$ valor $\rightarrow$ Bellman $\rightarrow$ optimalidad $\rightarrow$ caso degenerado del bandido.

Políticas: el lenguaje de la decisión

Política: definición formal

Una **política** es la regla que el agente emplea para seleccionar acciones a partir del estado observado. Formalmente:

Definición

Una política estocástica estacionaria es una aplicación

$$\pi : \mathcal{S} \times \mathcal{A} \longrightarrow [0, 1], \quad \text{tal que} \quad \sum_{a \in \mathcal{A}} \pi(a \mid s) = 1 \quad \forall s \in \mathcal{S}.$$

Se interpreta $\pi(a \mid s)$ como la probabilidad condicional de tomar la acción a dado el estado s .

Notación. Cuando el espacio de acciones es finito de cardinal $|\mathcal{A}| = k$, cada $\pi(\cdot \mid s)$ es un elemento del simplex Δ^{k-1} . La política π es entonces un objeto en $(\Delta^{k-1})^{|\mathcal{S}|}$.

Política determinista versus política estocástica

Determinista

$$\pi : \mathcal{S} \rightarrow \mathcal{A}, \quad a = \pi(s)$$

Equivale al caso estocástico con $\pi(a | s) \in \{0, 1\}$: toda la masa de probabilidad concentrada en una sola acción.

Cuándo basta lo determinista

En MDPs finitos con horizonte infinito descontado, **existe una política óptima determinista** (Puterman, 1994).

Estocástica

$$a \sim \pi(\cdot | s)$$

Distribución no degenerada sobre acciones. Permite **exploración intrínseca** y resulta indispensable en escenarios competitivos o parcialmente observables.

Cuándo se necesita aleatoriedad

Juegos de suma cero (piedra-papel-tijera), exploración durante el aprendizaje, MDPs parcialmente observables.

¿Por qué estudiar políticas estocásticas?

Existen al menos cuatro razones que justifican un tratamiento general:

1. **Exploración:** sin aleatoriedad el agente puede quedar atrapado en óptimos locales por desconocimiento del entorno.
2. **Robustez en juegos:** contra adversarios racionales, una política mixta puede ser estrictamente mejor (equilibrio de Nash mixto).
3. **Observabilidad parcial:** cuando el estado no captura toda la información relevante, romper simetrías mediante aleatorización puede mejorar el desempeño.
4. **Tratabilidad matemática:** las políticas estocásticas viven en un conjunto convexo, lo que facilita los argumentos analíticos y permite emplear gradientes (lo veremos en la Clase 5 con *policy gradients*).

Síntesis estadística

Pensar π como una distribución condicional $\pi(\cdot | s)$ habilita el uso del aparato bayesiano y de inferencia para razonar sobre la decisión.

Tres niveles de generalidad

- **General:** $\pi_t(a \mid h_t)$ depende de la historia completa $h_t = (s_0, a_0, \dots, s_t)$.
- **Markoviana:** $\pi_t(a \mid s_t)$ depende solo del estado actual.
- **Markoviana estacionaria:** $\pi(a \mid s)$ no depende del tiempo.

Resultado fundamental

Para MDPs finitos con horizonte infinito descontado, existe siempre una política óptima *markoviana, estacionaria y determinista*.

(Bertsekas & Tsitsiklis, 1996; Puterman, 1994.)

En este curso **nos restringiremos casi siempre al caso estacionario**, lo cual simplifica notablemente la teoría sin pérdida significativa de generalidad práctica.

Política y dinámica inducida

Dada una política π , la *dinámica inducida* sobre el espacio de estados se obtiene marginalizando la acción:

$$P^\pi(s' | s) = \sum_{a \in \mathcal{A}} \pi(a | s) P(s' | s, a)$$

De manera análoga, la recompensa esperada inducida:

$$R^\pi(s) = \sum_{a \in \mathcal{A}} \pi(a | s) R(s, a)$$

Lectura probabilística

El par (P^π, R^π) define una **cadena de Markov** sobre $\mathcal{S}$ con recompensas. El estudio del proceso recompensado bajo π es, en esencia, análisis de cadenas de Markov enriquecidas con *costos*.

Funciones de valor: la métrica del desempeño

Función de valor de estado V^π

Definición

La función de valor de estado bajo la política π se define como la esperanza del retorno desde s siguiendo π :

$$V^\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s] = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s \right].$$

- La esperanza $\mathbb{E}_\pi$ se toma sobre todas las trayectorias generadas por π y la dinámica P .
- Si $|\mathcal{S}| = n$ es finito, $V^\pi \in \mathbb{R}^n$ es un vector.
- Si las recompensas están acotadas, $|R(s, a)| \leq R_{\max}$, entonces $|V^\pi(s)| \leq R_{\max}/(1 - \gamma)$.

Interpretación

$V^\pi(s)$ cuantifica **cuán deseable** es comenzar en s y seguir la política π desde ahí en adelante. Es el equivalente probabilístico de la *función de coste por seguir un curso de acción*.

Definición

La función de valor estado-acción, o *action-value*, se define como:

$$Q^\pi(s, a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a].$$

Esto es: el retorno esperado al tomar la acción a en el estado s y, luego, seguir π .

Por qué Q es operativamente preferible a V

- Permite **mejorar la política sin conocer P** : basta con tomar $\arg \max_a Q^\pi(s, a)$.
- Es la cantidad central de Q-Learning, SARSA y DQN (Clases 4 y 5).
- Encapsula la consecuencia futura de una decisión local.

Relaciones canónicas entre V^π y Q^π

Las dos funciones de valor están vinculadas por dos identidades fundamentales:

Relación 1: V^π como promedio de Q^π

$$V^\pi(s) = \sum_{a \in \mathcal{A}} \pi(a | s) Q^\pi(s, a) = \mathbb{E}_{A \sim \pi(\cdot | s)}[Q^\pi(s, A)]$$

Relación 2: Q^π en términos de V^π

$$Q^\pi(s, a) = R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) V^\pi(s')$$

La primera muestra que V^π es un *marginal* de Q^π sobre la distribución de acciones. La segunda evidencia que Q^π es la *recompensa inmediata más el valor futuro descontado*, y prefigura la ecuación de Bellman.

La función de ventaja

Definición

La **función de ventaja** (*advantage function*) de una política π se define como

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s).$$

Lectura

- Mide *cuánto mejor* (o peor) es tomar la acción a en s respecto del valor promedio bajo π .
- Satisface $\mathbb{E}_{A \sim \pi(\cdot|s)}[A^\pi(s, A)] = 0$ por construcción.
- Es central en los métodos modernos de gradiente de política (Actor-Crítico, A2C, PPO; Clases 5 y 6).

Conexión estadística

Restar $V^\pi(s)$ a $Q^\pi(s, a)$ es análogo a usar un **control variate** para reducir varianza en estimadores Monte Carlo. Volveremos a este punto en la Clase 5.

Ilustración: valores en GridWorld

6.1	7.0	8.0	G
5.2	6.0	7.2	9.0
4.4			8.0
S	4.0	6.2	7.0

Valores aproximados V^π bajo política π casi-óptima.

Observaciones

- El valor crece monótonamente al aproximarse a la meta G.
- Los muros no tienen valor (estados inalcanzables).
- La diferencia entre celdas refleja el descuento $\gamma = 0.95$.

Pregunta

¿Por qué la celda (0,0) vale aproximadamente $V^\pi(S) \approx 6.1 \cdot 0.95^k$ para k pasos hasta G?

La ecuación de Bellman y el operador de Bellman

Una derivación heurística

Partamos de la definición de retorno y descompongamos el primer paso:

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = R_{t+1} + \gamma G_{t+1}.$$

Tomando esperanza condicional bajo π :

$$V^\pi(s) = \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} \mid S_t = s] = \mathbb{E}_\pi[R_{t+1} \mid S_t = s] + \gamma \mathbb{E}_\pi[G_{t+1} \mid S_t = s].$$

Argumento clave

El segundo término se reescribe usando la **propiedad de Markov** y la **ley de la esperanza total**:

$$\mathbb{E}_\pi[G_{t+1} \mid S_t = s] = \sum_a \pi(a \mid s) \sum_{s'} P(s' \mid s, a) V^\pi(s').$$

Teorema (Ecuación de Bellman para la evaluación)

Para todo $s \in \mathcal{S}$:

$$V^\pi(s) = \sum_{a \in \mathcal{A}} \pi(a | s) \left[R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) V^\pi(s') \right].$$

Lectura componente por componente

- $\sum_a \pi(a | s)$: promedio sobre las acciones que la política podría tomar.
- $R(s, a)$: recompensa inmediata esperada.
- $\gamma \sum_{s'} P(s' | s, a) V^\pi(s')$: valor futuro descontado promedio.

Una autoreferencia que no es circular

V^π aparece a ambos lados, pero el sistema resulta *lineal* en V^π y, con $\gamma < 1$, admite solución única.

Ecuación de Bellman para Q^π

La versión análoga para la función estado-acción se obtiene condicionando además sobre la acción inicial:

Ecuación de Bellman para Q^π

$$Q^\pi(s, a) = R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) \sum_{a' \in \mathcal{A}} \pi(a' | s') Q^\pi(s', a').$$

Comentario. La ecuación para Q^π resulta especialmente útil cuando P es **desconocida**: la actualización podrá implementarse muestreando transiciones (s, a, r, s', a') , dando lugar al algoritmo SARSA que veremos en la Clase 4.

Forma matricial y sistema lineal

Consideremos $\mathcal{S}$ finito de cardinal n . Definimos:

- $V^\pi \in \mathbb{R}^n$: vector de valores $[V^\pi(s_1), \dots, V^\pi(s_n)]^\top$.
- $R^\pi \in \mathbb{R}^n$: vector con $[R^\pi]_s = \sum_a \pi(a | s) R(s, a)$.
- $P^\pi \in \mathbb{R}^{n \times n}$: matriz con $[P^\pi]_{s,s'} = \sum_a \pi(a | s) P(s' | s, a)$.

La ecuación de Bellman se reescribe entonces como un **sistema lineal compacto**:

$$V^\pi = R^\pi + \gamma P^\pi V^\pi$$

Cuya solución cerrada es:

$$V^\pi = (I - \gamma P^\pi)^{-1} R^\pi.$$

Existencia de la inversa

Como $\gamma < 1$ y P^π es estocástica, $\|\gamma P^\pi\|_\infty = \gamma < 1$. La serie de Neumann $\sum_{k=0}^{\infty} (\gamma P^\pi)^k$ converge y $(I - \gamma P^\pi)$ es invertible.

El operador de Bellman $\mathcal{T}^\pi$

Definimos el **operador de Bellman para evaluación** $\mathcal{T}^\pi : \mathbb{R}^{|\mathcal{S}|} \rightarrow \mathbb{R}^{|\mathcal{S}|}$ como:

$$(\mathcal{T}^\pi V)(s) \equiv \sum_{a \in \mathcal{A}} \pi(a | s) \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V(s') \right].$$

En forma vectorial:

$$\mathcal{T}^\pi V = R^\pi + \gamma P^\pi V.$$

Reformulación

La ecuación de Bellman para V^π admite la lectura siguiente: **V^π es un punto fijo de $\mathcal{T}^\pi$.**

$$V^\pi = \mathcal{T}^\pi V^\pi.$$

$\mathcal{T}^\pi$ es una contracción

Proposición

El operador $\mathcal{T}^\pi$ es una contracción de módulo γ con respecto a la norma del supremo $\|\cdot\|_\infty$:

$$\|\mathcal{T}^\pi U - \mathcal{T}^\pi V\|_\infty \leq \gamma \|U - V\|_\infty \quad \forall U, V \in \mathbb{R}^{|S|}.$$

Demostración (esquema).

$$\begin{aligned} |(\mathcal{T}^\pi U)(s) - (\mathcal{T}^\pi V)(s)| &= \gamma \left| \sum_a \pi(a | s) \sum_{s'} P(s' | s, a) [U(s') - V(s')] \right| \\ &\leq \gamma \sum_a \pi(a | s) \sum_{s'} P(s' | s, a) |U(s') - V(s')| \\ &\leq \gamma \|U - V\|_\infty \cdot \underbrace{\sum_a \pi(a | s) \sum_{s'} P(s' | s, a)}_{=1}. \end{aligned}$$

Tomando supremo en s , queda probado. $\square$

Teorema del punto fijo de Banach

Teorema (Banach, 1922)

Sea $(\mathcal{X}, \|\cdot\|)$ un espacio de Banach y $\mathcal{T} : \mathcal{X} \rightarrow \mathcal{X}$ un operador contractivo con módulo $\gamma \in [0, 1)$. Entonces:

1. Existe un único punto fijo $V^* \in \mathcal{X}$ tal que $\mathcal{T}V^* = V^*$.
2. Para cualquier $V_0 \in \mathcal{X}$, la sucesión $V_{k+1} = \mathcal{T}V_k$ converge a V^* .
3. La convergencia es **geométrica**: $\|V_k - V^*\| \leq \gamma^k \|V_0 - V^*\|$.

Consecuencia para RL

Aplicado a $\mathcal{T}^\pi$, este teorema garantiza:

- Existencia y unicidad de V^π .
- Que el **algoritmo de evaluación iterativa de políticas** converja exponencialmente rápido.

Algoritmo: evaluación iterativa de la política

Iterative Policy Evaluation

Entrada: política π , MDP $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$, tolerancia $\theta > 0$.

Inicialización: $V_0(s) \leftarrow 0$ para todo $s \in \mathcal{S}$.

Repetir:

1. Para cada $s \in \mathcal{S}$:

$$V_{k+1}(s) \leftarrow \sum_a \pi(a | s) \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_k(s') \right]$$

2. $\Delta \leftarrow \max_s |V_{k+1}(s) - V_k(s)|$.

Hasta $\Delta < \theta$.

Salida: $V_k \approx V^\pi$.

Este procedimiento converge porque cada paso aplica $\mathcal{T}^\pi$, contractivo de módulo γ . La tolerancia θ controla el sesgo numérico final.

Política óptima y ecuación de Bellman óptima

Definición de optimalidad

Una política π^* es *óptima* si $V^{\pi^*}(s) \geq V^\pi(s)$ para todo $s \in \mathcal{S}$ y toda política π . Definimos:

$$V^*(s) \equiv \max_{\pi} V^\pi(s), \quad Q^*(s, a) \equiv \max_{\pi} Q^\pi(s, a).$$

Ecuación de optimalidad de Bellman

$$V^*(s) = \max_{a \in \mathcal{A}} \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V^*(s') \right]$$

$$Q^*(s, a) = R(s, a) + \gamma \sum_{s'} P(s' | s, a) \max_{a' \in \mathcal{A}} Q^*(s', a')$$

Obsérvese la diferencia crucial: el operador de evaluación promedia sobre $\pi(a | s)$; el operador de optimalidad **maximiza** sobre $\mathcal{A}$.

La ecuación de optimalidad para Q^* tiene una consecuencia operativa de enorme importancia:

Política óptima por extracción


Cualquier política

$$\pi^*(s) \in \arg \max_{a \in \mathcal{A}} Q^*(s, a)$$

es óptima. La maximización es local en s y **no requiere conocer P** .

Por qué esto importa. Si pudiéramos estimar Q^* a partir de experiencia muestreada, tendríamos automáticamente de una política óptima sin necesidad de conocer el modelo. Esta observación es el fundamento de **Q-Learning** (Clase 4) y **DQN** (Clase 5).

Mini-ejemplo numérico: un MDP de tres estados



Cadena de Markov inducida bajo una política fija π con $\gamma = 0.9$ y recompensas $R^\pi = (1, 2, 0)$.

Resolución del sistema $V^\pi = (I - \gamma P^\pi)^{-1} R^\pi$:

$$P^\pi = \begin{pmatrix} 0.2 & 0.8 & 0 \\ 0 & 0.3 & 0.7 \\ 1 & 0 & 0 \end{pmatrix}, \quad R^\pi = \begin{pmatrix} 1 \\ 2 \\ 0 \end{pmatrix}$$

$$V^\pi \approx \begin{pmatrix} 9.05 \\ 10.34 \\ 8.15 \end{pmatrix}$$

Verificación

$$V^\pi(s_1) = 1 + 0.9(0.2 \cdot 9.05 + 0.8 \cdot 10.34) \approx 9.05. \quad \checkmark$$

Limitaciones de la enumeración exacta

El enfoque *enumerar y resolver el sistema lineal* es factible solo bajo dos condiciones:

1. **Modelo conocido:** se dispone de P y R explícitos.
2. **Cardinalidad manejable:** $|\mathcal{S}|$ debe ser computacionalmente abordable. Resolver $(I - \gamma P^\pi)^{-1}$ tiene complejidad $\mathcal{O}(|\mathcal{S}|^3)$.

La realidad de los problemas interesantes

En la mayoría de las aplicaciones, P es desconocida (un robot no sabe su dinámica) o $|\mathcal{S}|$ es enorme (en Go, $|\mathcal{S}| \approx 10^{170}$). Ambos obstáculos motivan los métodos **model-free** basados en muestreo que abordaremos en la Clase 3.

Antes de llegar allí, exploraremos un caso límite donde la teoría se vuelve transparente: **el bandido multibrazo**.

El problema del bandido multibrazo

De MDP a bandido: un caso límite

El **problema del bandido multibrazo** es el MDP más simple que aún ilumina el dilema exploración-explotación:

- Un único estado: $|\mathcal{S}| = 1$. (Conceptualmente: *el casino*.)
- k acciones disponibles: $\mathcal{A} = \{1, 2, \dots, k\}$. (Cada *brazo* de una máquina tragamonedas.)
- Cada acción a produce una recompensa estocástica $R_t \sim \nu_a$ con media desconocida $q_*(a) = \mathbb{E}[R \mid A = a]$.
- No hay transición de estado: el problema es **secuencial pero no markoviano** en el sentido pleno.

Por qué nos interesa

El bandido aísla el dilema central del RL — **explorar** (probar acciones poco conocidas para aprender sobre ellas) versus **explotar** (capitalizar lo que ya se ha aprendido) — sin las complicaciones derivadas de la dinámica de estados.

Una breve genealogía

- **Thompson (1933)**: primer planteo formal en el contexto de ensayos clínicos. ¿Cómo asignar pacientes a tratamientos cuando cada decisión es vital y los efectos son inciertos?
- **Robbins (1952)**: formalización moderna; introducción del concepto de *regret*.
- **Lai & Robbins (1985)**: cota inferior asintótica para el regret: cualquier algoritmo razonable padece $\Omega(\log T)$.
- **Auer, Cesa-Bianchi & Fischer (2002)**: algoritmo *UCB1* alcanza esa cota.

Una conexión profunda

El bandido pertenece a la familia del *diseño secuencial de experimentos*, tradición estadística que el RL moderno extiende y generaliza. Lo abordamos en este curso desde esa óptica.

Formalización y métricas de desempeño

Asumimos k distribuciones desconocidas $\{\nu_a\}_{a=1}^k$ con medias $q_*(a)$. Sea $a^* = \arg \max_a q_*(a)$ el brazo óptimo y $q^* = q_*(a^*)$.

Métricas centrales sobre un horizonte T

- Recompensa acumulada: $\sum_{t=1}^T R_t$.
- **Regret acumulado esperado:**

$$\mathfrak{R}_T = T \cdot q^* - \mathbb{E} \left[\sum_{t=1}^T R_t \right] = \sum_{a \neq a^*} \Delta_a \cdot \mathbb{E}[N_a(T)],$$

donde $\Delta_a = q^* - q_*(a)$ es la *brecha de suboptimalidad* y $N_a(T)$ es el número de veces que el brazo a se eligió.

El objetivo es **minimizar el regret**: cada vez que el algoritmo elige un brazo distinto del óptimo, paga Δ_a .

Estimación incremental del valor de acción

Sea $\hat{Q}_t(a)$ el promedio empírico de las recompensas obtenidas al jugar el brazo a hasta el instante t . Si se actualiza tras cada jugada de a :

$$\hat{Q}_{n+1}(a) = \hat{Q}_n(a) + \frac{1}{n+1} [R_{n+1} - \hat{Q}_n(a)].$$

Lectura estadística

Esta es la fórmula recursiva del promedio muestral. La cantidad $R_{n+1} - \hat{Q}_n(a)$ funciona como **error de predicción**: si la nueva observación supera la estimación previa, el promedio sube; en caso contrario, baja.

Versión con tasa constante

$$\hat{Q}_{n+1}(a) = \hat{Q}_n(a) + \alpha [R_{n+1} - \hat{Q}_n(a)], \quad \alpha \in (0, 1].$$

Útil en escenarios *no estacionarios* (la distribución de recompensa cambia con el tiempo): el estimador olvida exponencialmente las observaciones antiguas.

Estrategia 1: ε -greedy

La primera regla de decisión, simple y robusta:

Política ε -greedy

En cada instante t :

$$A_t = \begin{cases} \arg \max_a \hat{Q}_t(a), & \text{con probabilidad } 1 - \varepsilon, \\ \text{acción uniforme en } \mathcal{A}, & \text{con probabilidad } \varepsilon. \end{cases}$$

Propiedades cualitativas

- Toda acción se elige con probabilidad al menos $\varepsilon/k > 0$, garantizando **exploración perpetua**.
- Cada $\hat{Q}_t(a) \rightarrow q_*(a)$ casi seguramente (por ley fuerte de los grandes números).
- Compromiso entre exploración y explotación regulado por ε .

Las dos críticas principales

1. **Exploración indiscriminada.** Con probabilidad ε se elige uniformemente, sin distinguir brazos casi-óptimos de brazos claramente malos.
2. **Regret lineal en T .** Para ε constante, $\mathfrak{R}_T = \Theta(\varepsilon T)$. Aunque se aprende, el costo acumulado crece linealmente.

Mejoras heurísticas

- $\varepsilon_t = c/t$ con c ajustada.
- Decaimiento exponencial $\varepsilon_t = \varepsilon_0 \alpha^t$.
- *Optimistic initialization*: $\hat{Q}_0(a)$ muy alto fuerza exploración inicial.

La pregunta natural

¿Existe un algoritmo cuyo regret crezca solo **logarítmicamente** en T ? La respuesta afirmativa la dan los métodos de *optimismo bajo incertidumbre*.

Estrategia 2: optimismo bajo incertidumbre (UCB)

Idea central. Asignar a cada brazo un *bono de incertidumbre*: cuanto menos veces se haya jugado, mayor su bonificación. Se elige el brazo cuyo **límite superior de confianza** sea máximo.

Algoritmo UCB1 (Auer, Cesa-Bianchi & Fischer, 2002)

En el instante t , seleccionar:

$$A_t = \arg \max_{a \in \mathcal{A}} \left[\hat{Q}_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right]$$

donde $N_t(a)$ es el número de veces que a fue jugado y $c > 0$ regula el grado de exploración.

Interpretación. El término $\sqrt{\ln t / N_t(a)}$ deriva de la desigualdad de Hoeffding: con alta probabilidad, $|\hat{Q}_t(a) - q_*(a)|$ está acotada por una cantidad de ese orden. UCB toma esa cota **como si fuera la verdad**, principio conocido como *optimismo bajo incertidumbre*.

Teorema (Auer, Cesa-Bianchi & Fischer, 2002)

Para UCB1 con $c = \sqrt{2}$, el regret esperado satisface

$$\mathfrak{R}_T \leq \sum_{a: \Delta_a > 0} \left[\frac{8 \ln T}{\Delta_a} + \left(1 + \frac{\pi^2}{3}\right) \Delta_a \right] = \mathcal{O}(\log T).$$

Cota inferior de Lai-Robbins

Para cualquier algoritmo *consistente* (es decir, que no explore un subóptimo con frecuencia constante),

$$\liminf_{T \rightarrow \infty} \frac{\mathfrak{R}_T}{\ln T} \geq \sum_{a: \Delta_a > 0} \frac{\Delta_a}{\text{KL}(\nu_a \parallel \nu_{a^*})}.$$

UCB **alcanza el orden óptimo** hasta un factor constante.

Estrategia 3: Thompson sampling

Una perspectiva **bayesiana** sobre el mismo problema.

Esquema general


1. Mantener una distribución *a posteriori* $\pi_t(q_a)$ sobre la media $q_*(a)$ de cada brazo.
2. En el instante t , muestrear $\tilde{q}_a \sim \pi_t(q_a)$ independientemente para cada a .
3. Elegir $A_t = \arg \max_a \tilde{q}_a$.
4. Observar R_t y actualizar π_{t+1} mediante la regla de Bayes.

Caso Bernoulli con prior Beta

Si $R_t \in \{0, 1\}$ y $\pi_0(q_a) = \text{Beta}(\alpha_a, \beta_a)$, entonces $\pi_t(q_a) = \text{Beta}(\alpha_a + s_a, \beta_a + f_a)$, donde s_a, f_a son éxitos y fracasos observados.

Thompson sampling también alcanza regret $\mathcal{O}(\log T)$ y, en la práctica, suele superar a UCB en problemas reales (Chapelle & Li, 2011).

Visualización: regret comparado



Lectura. El regret de ϵ -greedy crece linealmente con la pendiente $\epsilon \sum_a \Delta_a / k$. UCB y Thompson exhiben crecimiento logarítmico, asintóticamente muy inferior.

Cuadro comparativo de estrategias

Criterio	ϵ -greedy	UCB1	Thompson
Filosofía	Aleatoriedad controlada	Optimismo bajo incertidumbre	Inferencia bayesiana
Regret asintótico	$\Theta(\epsilon T)$ lineal	$\mathcal{O}(\log T)$	$\mathcal{O}(\log T)$
Hiperparámetros	ϵ	c	Prior
Implementación	Trivial	Sencilla	Requiere prior conjugado
Desempeño empírico	Aceptable	Bueno	A menudo el mejor
Extensible a MDP	Sí, ampliamente	Limitada	Sí, con cuidado

Recomendación práctica

En la Clase 4 (ϵ -greedy aplicada a SARSA y Q-Learning) volveremos sobre la primera familia, pero conviene retener que en bandits puros, **Thompson sampling suele ser el caballo ganador**.

Extensión natural: bandidos contextuales

Un paso intermedio entre el bandido y el MDP completo:

- Antes de cada decisión, el agente observa un *contexto* $x_t \in \mathcal{X}$ (covariables).
- La recompensa depende del contexto: $R_t \sim \nu_{a, x_t}$ con $\mathbb{E}[R_t \mid a, x_t] = q_*(a, x_t)$.
- No hay transición de estado: el contexto futuro es exógeno (independiente de las acciones).

Aplicaciones tangibles

- Recomendación personalizada (Netflix, noticias).
- Asignación de tratamientos médicos según historia clínica.
- Subastas de anuncios en línea.

El bandido contextual es estudiado intensamente en la literatura estadística reciente y puede abordarse, en R, con el paquete `contextual`, parte de nuestra pila computacional.

Trabajo práctico, anticipo y bibliografía

Contenido del cuaderno (Python y R)

1. Resolución cerrada de la ecuación de Bellman para una política fija en GridWorld con $|S| = 16$.
2. Implementación de `iterative_policy_evaluation` y verificación de la tasa de convergencia geométrica.
3. Bandido de 10 brazos con recompensas gaussianas: réplica del experimento de Sutton & Barto (figura 2.2).
4. Comparación cuantitativa de ϵ -greedy ($\epsilon \in \{0, 0.01, 0.1\}$), UCB ($c \in \{1, 2\}$) y Thompson sampling sobre 1000 corridas.
5. Análisis estadístico del regret: media, desviación estándar y bandas de confianza al 95%.

Versión R

Cuaderno paralelo en R Markdown empleando los paquetes nativos `bandit`, `contextual` y `MDPtoolbox`, conmensurable con la versión en Python.

Ejercicios propuestos

1. **Ejercicio teórico 1.** Demuestre que el operador de optimalidad

$$(\mathcal{T}^* V)(s) = \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V(s') \right]$$

también es contractivo de módulo γ en $\|\cdot\|_\infty$. (Pista: $|\max f - \max g| \leq \max |f - g|$.)

2. **Ejercicio computacional 1.** Para el MDP de tres estados de la diapositiva 19, calcule V^π por dos vías: (a) inversión exacta de $(I - \gamma P^\pi)$; (b) iteración del operador $\mathcal{T}^\pi$. Reporte el número de iteraciones necesario para $\|V_{k+1} - V_k\|_\infty < 10^{-6}$.
3. **Ejercicio computacional 2.** En un bandido de 10 brazos con $q_*(a) \sim \mathcal{N}(0, 1)$, compare ε -greedy, UCB y Thompson sobre $T = 2000$ pasos y $N = 500$ réplicas. Reporte el regret esperado en $T = 2000$ con intervalo de confianza.
4. **Ejercicio teórico 2 (avanzado).** Pruebe que en el problema de Bernoulli con prior Beta(1, 1), Thompson sampling es equivalente, en el primer paso, a una elección uniforme sobre brazos.

Lo que viene en la Clase 3

Habiendo establecido cómo *evaluar* una política cuando el modelo es conocido, la pregunta natural es:

Pregunta central de la Clase 3

¿Cómo estimar V^π y Q^π cuando P es desconocida y solo disponemos de muestras de trayectorias?

Contenidos centrales del 19 de mayo

- **Métodos Monte Carlo:** promediar retornos sobre trayectorias completas; sesgo nulo, alta varianza.
- **Diferencias Temporales TD(0):** actualización paso a paso,
 $V(S_t) \leftarrow V(S_t) + \alpha[R_{t+1} + \gamma V(S_{t+1}) - V(S_t)]$. La quintaesencia del *bootstrapping*.
- Comparación de convergencia y eficiencia muestral: sesgo-varianza redivivo.
- Implementación guiada en GridWorld estocástico.

Allí veremos cómo el operador $\mathcal{T}^\pi$ se convierte, mediante el muestreo, en una estimación recursiva.

Para esta semana: trabajo entre encuentros

Tareas sincrónicas (no entregables)

1. Lectura de Sutton & Barto, **Capítulo 2 completo** y **Capítulo 3 secciones 3.5–3.8**.
2. Ejecución del notebook `Clase02_Bellman_Bandits.ipynb` en Python o R.
3. Reproducción de la Figura 2.2 de Sutton & Barto.

Entrega evaluativa (Unidad 1)

Fecha límite: 18 de mayo, 23:59 hs. Resolver los ejercicios teóricos 1 y 2 más el ejercicio computacional 2. Entrega vía aula virtual en PDF + notebook ejecutado. Constituye el 10% de la nota final (parte de la primera de las tres entregas por unidad).

Foro abierto

Dudas sobre el operador de Bellman, demostraciones intermedias o cuestiones de implementación: foro de consultas específico de la Clase 2.

Bibliografía obligatoria de la Clase 2

- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2.^a ed.). MIT Press. **Capítulo 2 completo** (bandits) y **Capítulo 3, secciones 3.5–3.8** (políticas óptimas y ecuación de Bellman).
- Zhao, S. (2024). *Mathematical Foundations of Reinforcement Learning*. Springer. **Capítulos 2 y 3** (Bellman, operadores, optimalidad).

Lectura complementaria

Profundización teórica

- Bertsekas, D. P. (2019). *Reinforcement Learning and Optimal Control*. **Capítulo 1, secciones 1.1–1.3; Capítulo 4, secciones 4.2–4.3** (operadores DP y contracción).
- Agarwal, A., Jiang, N., Kakade, S. M., & Sun, W. (2022). *Reinforcement Learning: Theory and Algorithms*. **Capítulo 6** (bandits, cotas de regret).
- Murphy, K. P. (2024). *Probabilistic Machine Learning: Advanced Topics*. **Secciones 34.4 y 35.1.5** (bandits y exploración).

Material aplicado

- Lapan, M. (2024). *Deep Reinforcement Learning Hands-On* (3.^a ed.). Packt. **Capítulo 5** (entornos de bandits con Gymnasium).
- Ghavamzadeh, M., *et al.* (2015). *Bayesian Reinforcement Learning: A Survey*. Sección 4 (Thompson sampling y enfoques bayesianos).

Lectura clásica recomendada

Auer, P., Cesa-Bianchi, N., & Fischer, P. (2002). Finite-time analysis of the multi-armed bandit problem. *Machine Learning*, 47(2), 235–256.

Hasta la próxima semana

Clase 3 — Métodos Monte Carlo y Diferencias Temporales

19 de mayo de 2026, 18 a 21 hs

*«La teoría sin la práctica es un castillo en el aire;
la práctica sin la teoría es ceguera con ruido».*

— Adaptado de I. Kant.