

Aprendizaje por Refuerzo

Fundamentos y Aplicaciones

Clase 3 – Métodos Monte Carlo y Diferencias Temporales TD(0)

Dr. Darío Ezequiel Díaz

19 de mayo de 2026

Facultad de Ingeniería – Posgrados
Universidad Austral

Hoja de ruta del encuentro

Recapitulación de la Clase 2 y puente conceptual

El problema de la predicción libre de modelo

Métodos Monte Carlo para la predicción

Aprendizaje por Diferencias Temporales TD(0)

Comparación entre Monte Carlo y TD(0)

Trabajo práctico, anticipo y bibliografía

Recapitulación de la Clase 2 y puente conceptual

Lo que consolidamos la semana pasada

Funciones de valor

$$V^{\pi}(s) = \mathbb{E}_{\pi}[G_t | S_t = s],$$
$$Q^{\pi}(s, a) = \mathbb{E}_{\pi}[G_t | S_t = s, A_t = a].$$

Ecuación de Bellman

$$V^{\pi}(s) = \sum_a \pi(a|s) \sum_{s'} P(s'|s, a) [R(s, a) + \gamma V^{\pi}(s')].$$

Operador de Bellman $\mathcal{T}^{\pi}$

- Contracción de módulo γ en $\|\cdot\|_{\infty}$.
- Punto fijo único: $\mathcal{T}^{\pi} V^{\pi} = V^{\pi}$.
- Iteración de evaluación: convergencia geométrica.

Bandido multibrazo

Caso degenerado del MDP con $|\mathcal{S}| = 1$.
Estrategias ε -greedy, UCB, Thompson sampling.

La fisura que abre la Clase 3

Toda la maquinaria de la Clase 2 presupone un ingrediente decisivo:

Hipótesis tácita de la evaluación clásica

La dinámica $P(s'|s, a)$ y la recompensa esperada $R(s, a)$ son *conocidas* por el agente.


Pero en la inmensa mayoría de los problemas auténticos –robótica, finanzas, salud, sistemas de recomendación– esta hipótesis sencillamente no se sostiene. El agente *no* dispone de un modelo: posee únicamente acceso a la experiencia, esto es, a trayectorias muestreadas por interacción.

Pregunta vertebradora de hoy

¿Cómo estimar V^π y Q^π cuando el modelo del entorno permanece opaco y solo contamos con trayectorias

$(S_0, A_0, R_1, S_1, A_1, R_2, \dots)$?

Mapa conceptual del encuentro



Hoy transitamos de la programación dinámica exacta hacia el aprendizaje a partir de la experiencia.

El problema de la predicción libre de modelo

Predicción versus control: una distinción cardinal

Predicción (policy evaluation)

Dada una política π fija, estimar V^π o Q^π .

Tareas centrales de la **Unidad 2**.

Control

Hallar una política óptima π^* que maximice el retorno esperado.

Tareas centrales de la **Unidad 3** (a partir de la Clase 4).

Ubicación de la Clase 3

Permanecemos íntegramente en el régimen de predicción. La cuestión *cómo decidir mejor* se posterga hasta la próxima semana; hoy nos preguntamos *cómo evaluar lo que el agente ya ha decidido*.

Distinción metodológica afín a la dicotomía estadística estimación–decisión, o a la separación econométrica entre identificación y política óptima.

Por qué necesitamos métodos basados en muestras

La fórmula cerrada $V^\pi = (I - \gamma P^\pi)^{-1} R^\pi$ exige cinco condiciones, raramente satisfechas en conjunto:

1. Conocimiento completo de P y R .
2. Tamaño de $\mathcal{S}$ tratable computacionalmente (inversión $O(|\mathcal{S}|^3)$).
3. Espacio discreto y finito.
4. Estacionariedad de la dinámica.
5. Verificación de la propiedad de Markov sobre la representación adoptada.

La salida es estadística

Cuando el modelo es opaco, retornamos al recurso primordial del estadístico: **estimar esperanzas mediante promedios muestrales**. Aquí reside el origen del aprendizaje por refuerzo libre de modelo.

Recordatorio: estimación Monte Carlo en estadística

Sea X variable aleatoria con esperanza $\mu = \mathbb{E}[X]$ desconocida, y sean $X_1, \dots, X_n$ realizaciones i.i.d. El estimador muestral

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

satisface, por la **Ley Fuerte de los Grandes Números**,

$$\bar{X}_n \xrightarrow{\text{c.s.}} \mu \quad \text{cuando } n \rightarrow \infty,$$

con error cuadrático medio $\mathbb{E}[(\bar{X}_n - \mu)^2] = \text{Var}(X)/n$.

Idea aplicada al RL

Reemplacemos X por el retorno G_t condicionado a partir del estado s . El promedio sobre múltiples trayectorias que pasaron por s constituye una estimación de $V^\pi(s) = \mathbb{E}[G_t \mid S_t = s]$.

Métodos Monte Carlo para la predicción

Principio

Si pudiéramos observar trayectorias completas bajo π hasta su terminación, el retorno realizado G_t constituiría una muestra insesgada de $V^\pi(S_t)$. El promedio de tales retornos, sobre suficientes episodios, convergerá a la función de valor verdadera.

Tres requerimientos operativos:

1. **Tareas episódicas:** debe existir un estado terminal alcanzable con probabilidad uno.
2. **Cobertura:** todo estado de interés debe ser visitado con probabilidad positiva bajo π (o *exploring starts*).
3. **Trayectorias completas:** no actualizamos V hasta finalizar el episodio.

El nombre alude al Casino de Mónaco, en metonimia introducida por Metropolis y Ulam (1949) en el contexto del Proyecto Manhattan.

Formalización: first-visit y every-visit

Considérese un episodio $\tau = (S_0, A_0, R_1, S_1, \dots, S_T)$ generado por π . Para un estado s , defínase el conjunto de instantes en los que se visita s :

$$\mathcal{V}(s) = \{t \in \{0, 1, \dots, T-1\} : S_t = s\}.$$

First-visit MC

Promediar únicamente los retornos asociados a la *primera* visita de s en cada episodio:

$$\hat{V}(s) = \frac{1}{N(s)} \sum_{e=1}^{N(s)} G_{t_1(s)}^{(e)},$$

con $t_1(s) = \min \mathcal{V}(s)$.

Every-visit MC

Promediar los retornos de *todas* las visitas a s , en cada episodio:

$$\hat{V}(s) = \frac{1}{M(s)} \sum_{e=1}^E \sum_{t \in \mathcal{V}_e(s)} G_t^{(e)}.$$

Diferencia esencial

First-visit promedia muestras independientes; every-visit incluye retornos correlacionados dentro del mismo episodio. Ambas variantes son consistentes; first-visit es la más estudiada teóricamente.

Algoritmo: First-visit MC para predicción

Algorithm 1 *

First-visit Monte Carlo Prediction

- 1: **Entrada:** política π ; número de episodios E .
- 2: **Inicializar:** $\hat{V}(s) \leftarrow 0$ y $\text{Returns}(s) \leftarrow \emptyset$ para todo $s \in \mathcal{S}$.
- 3: **for** $e = 1, 2, \dots, E$ **do**
- 4: Generar episodio $\tau_e = (S_0, A_0, R_1, S_1, \dots, S_T)$ siguiendo π .
- 5: $G \leftarrow 0$.
- 6: **for** $t = T - 1, T - 2, \dots, 0$ **do**
- 7: $G \leftarrow \gamma G + R_{t+1}$.
- 8: **if** S_t no aparece en $S_0, S_1, \dots, S_{t-1}$ **then** ▷ Primera visita
- 9: Agregar G a $\text{Returns}(S_t)$.
- 10: $\hat{V}(S_t) \leftarrow \text{media}(\text{Returns}(S_t))$.
- 11: **end if**
- 12: **end for**
- 13: **end for**

Implementación incremental

Mantener todos los retornos en memoria resulta inviable cuando E crece. Se reemplaza el promedio explícito por la **fórmula recursiva del promedio muestral**:

Actualización incremental

$$\widehat{V}_{n+1}(s) = \widehat{V}_n(s) + \frac{1}{n+1} \left[G_{n+1} - \widehat{V}_n(s) \right].$$

Esta expresión admite una lectura como esquema de **aproximación estocástica**:

$$\widehat{V}(s) \leftarrow \widehat{V}(s) + \alpha_n \left[G - \widehat{V}(s) \right]$$

con paso $\alpha_n = 1/n$ (Monte Carlo clásico) o paso constante α (variante incremental no estacionaria, idéntica forma).

El paso constante introduce un sesgo permanente, pero permite rastrear distribuciones no estacionarias: observación crucial para la transición hacia TD.

Propiedades estadísticas de Monte Carlo

Sea $\hat{V}_E(s)$ el estimador first-visit tras E episodios y $N_E(s)$ el número de primeras visitas a s . Bajo cobertura adecuada:

Insesgadez y consistencia

- $\mathbb{E}[\hat{V}_E(s)] = V^\pi(s)$ para todo E tal que $N_E(s) > 0$: **insesgado**.
- $\hat{V}_E(s) \xrightarrow{\text{c.s.}} V^\pi(s)$ cuando $E \rightarrow \infty$: **consistente**.
- Tasa: $\mathbb{E}[(\hat{V}_E(s) - V^\pi(s))^2] = \text{Var}_\pi(G_t \mid S_t = s) / N_E(s)$.

El problema de la varianza

$\text{Var}_\pi(G_t)$ puede ser *enorme*, pues G_t suma muchas variables aleatorias correlacionadas. Si los episodios son largos y la dinámica estocástica, MC exige multitud de trayectorias para producir estimaciones útiles.

Para utilizar el valor estimado en algoritmos de control (Clase 4), no basta con V^π : se requiere $Q^\pi(s, a)$. La extensión es inmediata: se promedian los retornos correspondientes a pares estado-acción visitados.

Dificultad práctica: cobertura de (s, a)

Si π es determinista, muchas combinaciones (s, a) *nunca* se observan, y $\hat{Q}(s, a)$ queda sin definición operativa.

Dos remedios habituales:

- **Exploring starts** (Sutton & Barto, §5.3): los episodios comienzan en pares (s, a) aleatoriamente sorteados con probabilidad positiva sobre todo $\mathcal{S} \times \mathcal{A}$.
- **Políticas ϵ -soft**: se garantiza $\pi(a|s) > 0$ para todo (s, a) –tema central de la próxima clase.

Limitaciones operativas de Monte Carlo

Ventajas

- Insesgado.
- No requiere modelo alguno.
- Conceptualmente diáfano.
- Se concentra automáticamente en regiones visitadas.
- Robusto frente a violaciones de Markov: utiliza la trayectoria entera.

Limitaciones

- Requiere tareas **episódicas**.
- Actualización **diferida**: nada se aprende hasta el final.
- **Varianza elevada** en episodios largos.
- Cobertura inadecuada si π es determinista.
- No explota la estructura recursiva del problema.

La pregunta natural

¿Es posible aprender incrementalmente, paso a paso, sin esperar la terminación del episodio, manteniendo la sobriedad estadística del muestreo? Aquí emerge el aprendizaje por diferencias temporales.

Aprendizaje por Diferencias Temporales TD(0)

La intuición de Sutton: bootstrapping

Recordemos la ecuación de Bellman en su forma de *esperanza recursiva*:

$$V^\pi(s) = \mathbb{E}_\pi[R_{t+1} + \gamma V^\pi(S_{t+1}) \mid S_t = s].$$

Monte Carlo emplea como objetivo de aprendizaje el retorno completo:

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$$

La idea TD

Sustituir el resto del retorno $\gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$ por su *estimación actual* $\gamma \hat{V}(S_{t+1})$.
Reemplazamos así una muestra exacta por una observación parcial más una estimación:
aprendemos sobre la base de otra estimación. Este artificio se denomina **bootstrapping**.

El objetivo TD y la regla de actualización

Objetivo TD

$$Y_t^{\text{TD}} := R_{t+1} + \gamma \widehat{V}(S_{t+1}).$$

Aplicando el mismo esquema de aproximación estocástica que utilizamos en MC incremental:

$$\widehat{V}(S_t) \leftarrow \widehat{V}(S_t) + \alpha \left[Y_t^{\text{TD}} - \widehat{V}(S_t) \right].$$

Substituyendo el objetivo:

$$\widehat{V}(S_t) \leftarrow \widehat{V}(S_t) + \alpha \left[R_{t+1} + \gamma \widehat{V}(S_{t+1}) - \widehat{V}(S_t) \right]$$

El *TD-error* δ_t

La expresión entre corchetes

$$\delta_t = R_{t+1} + \gamma \widehat{V}(S_{t+1}) - \widehat{V}(S_t)$$

constituye el **error de diferencia temporal**: cantidad central de toda la familia de algoritmos que veremos a partir de hoy.

Algoritmo: TD(0) para predicción

Algorithm 2 *

Tabular TD(0)

- 1: **Entrada:** política π ; paso $\alpha \in (0, 1]$; número de episodios E .
 - 2: **Inicializar:** $\hat{V}(s) \leftarrow 0$ (o un valor arbitrario) para todo $s \in \mathcal{S}$; $\hat{V}(s_{\text{terminal}}) \leftarrow 0$.
 - 3: **for** cada episodio $e = 1, \dots, E$ **do**
 - 4: Observar estado inicial S .
 - 5: **while** S no es terminal **do**
 - 6: Seleccionar $A \sim \pi(\cdot \mid S)$.
 - 7: Ejecutar A , observar recompensa R y estado siguiente S' .
 - 8: $\hat{V}(S) \leftarrow \hat{V}(S) + \alpha [R + \gamma \hat{V}(S') - \hat{V}(S)]$. ▷ Actualización TD
 - 9: $S \leftarrow S'$.
 - 10: **end while**
 - 11: **end for**
-

Observación. La actualización es local y se ejecuta en línea, tras cada transición; no se almacenan retornos.

TD(0) como aproximación estocástica del operador de Bellman

La regla TD admite una lectura profunda: estimar V^π mediante la iteración estocástica del operador de Bellman $\mathcal{T}^\pi$.

Descomposición conceptual

$$\underbrace{\mathbb{E}_\pi [R_{t+1} + \gamma V^\pi(S_{t+1}) \mid S_t = s]}_{\mathcal{T}^\pi V^\pi(s)} \approx \underbrace{R_{t+1} + \gamma \hat{V}(S_{t+1})}_{\text{muestra estocástica}}.$$

La actualización TD(0) implementa, por tanto, un esquema de Robbins-Monro: bajo condiciones estándar sobre la sucesión de pasos,

$$\sum_{n=1}^{\infty} \alpha_n = \infty, \quad \sum_{n=1}^{\infty} \alpha_n^2 < \infty,$$

el estimador converge casi seguramente al punto fijo del operador, es decir, a V^π .

Referencia teórica: Bertsekas & Tsitsiklis (1996), *Neuro-Dynamic Programming*; Zhao (2024), capítulos 6–7.

Convergencia de TD(0): enunciado riguroso

Teorema (Convergencia tabular de TD(0))

Supóngase un MDP finito con $\gamma \in [0, 1)$. Sea π una política tal que toda transición (s, a, s') con $\pi(a|s) > 0$ y $P(s'|s, a) > 0$ ocurre infinitas veces. Sea $\{\alpha_n(s)\}$ una sucesión de pasos de aprendizaje aplicada al estado s que verifica las condiciones de Robbins-Monro. Entonces, el estimador TD(0) satisface

$$\hat{V}_n(s) \xrightarrow{\text{c.s.}} V^\pi(s) \quad \forall s \in \mathcal{S}.$$

Implicancias prácticas

- Pasos $\alpha_n = 1/n$ verifican Robbins-Monro y aseguran convergencia, pero resultan lentos en la práctica.
- Pasos constantes α son sesgados pero permiten rastrear cambios en entornos no estacionarios.
- La condición de visitación infinita exige cobertura: he aquí, de nuevo, el dilema exploración-explotación.

¿Qué estima realmente cada método? La distinción ML/LS

Supongamos que, tras observar E episodios, congelamos la información y *ajustamos* ambos estimadores hasta su convergencia (batch updating). Surge una distinción profunda:

Monte Carlo en batch

Minimiza el error cuadrático medio entre las predicciones y los retornos observados:

$$\sum_{e,t} (\hat{V}(S_t^{(e)}) - G_t^{(e)})^2.$$

Estimador de mínimos cuadrados sobre las muestras.

TD(0) en batch

Converge al estimador de máxima verosimilitud del proceso markoviano subyacente, asumiendo la propiedad de Markov. Equivale a la solución exacta de la ecuación de Bellman sobre el MDP *empírico* construido con las transiciones observadas.

Lectura clave

TD(0) explota la estructura markoviana; MC permanece agnóstico respecto de ella. Cuando Markov se cumple, TD aprovecha esa información y converge a una mejor estimación poblacional con menos datos. Cuando Markov se transgrede, MC resulta más robusto.

Ilustración cualitativa: el manejo de un automóvil

Adaptación del célebre ejemplo de Sutton & Barto, §6.1.

Situación. Conduce usted a su domicilio. Al iniciar la travesía, estima que llegará en 30 minutos. Tras 5 minutos, advierte que un embotellamiento ha tornado lentísimo el tránsito; reestima 35 minutos. Tras otros 10 minutos el flujo retoma su cadencia; reestima 32 minutos. Finalmente arriba en 33 minutos.

Monte Carlo

Aguarda a llegar a destino. Al observar que tardó 33 minutos, corrige la *estimación inicial* en $\alpha(33 - 30)$.

TD(0)

Al ver el embotellamiento (instante $t = 5$), ya corrige: la nueva estimación 35 modifica la anterior 30 en $\alpha(5 + 35 - 30)$. No es preciso esperar al desenlace.

Esta capacidad de *aprender de cada paso* confiere a TD un sesgo (las estimaciones bootstrap son ruidosas), pero también una eficiencia muestral notable.

Comparación entre Monte Carlo y TD(0)

Cuadro comparativo

Criterio	Monte Carlo	TD(0)
Esquema de actualización	Por episodio completo	Por transición individual
Requiere tareas episódicas	Sí	No
Bootstrapping	No	Sí
Sesgo del estimador	Insesgado	Sesgado (durante el aprendizaje)
Varianza	Alta	Moderada
Velocidad de convergencia	Lenta cuando T es grande	Generalmente más rápida
Sensibilidad a Markov	Baja	Alta (lo aprovecha)
Uso de memoria	Almacena retornos por episodio	Mínimo (en línea)
Generalización a control	MC con ϵ -soft (Cl. 4)	SARSA, Q-Learning, DQN

Esta tabla constituye una guía operativa, no un veredicto definitivo: la elección depende del problema, del horizonte y de la cobertura.

El compromiso sesgo–varianza, formalizado

Sea $\hat{\theta}$ un estimador de un parámetro θ . Su error cuadrático medio admite la conocida descomposición:

$$\mathbb{E}[(\hat{\theta} - \theta)^2] = \underbrace{(\mathbb{E}[\hat{\theta}] - \theta)^2}_{\text{sesgo}^2} + \underbrace{\text{Var}(\hat{\theta})}_{\text{varianza}}.$$

Monte Carlo

- Sesgo = 0 (estimador insesgado del retorno esperado).
- Varianza grande, escala con la longitud del episodio.

TD(0)

- Sesgo $\neq 0$ durante el aprendizaje (depende de $\hat{V}(S_{t+1})$).
- Varianza moderada: el objetivo TD depende de una sola transición.

Lectura estadística

En muchos regímenes prácticos, un estimador ligeramente sesgado pero de varianza reducida produce mejor error cuadrático medio que un insesgado de gran dispersión. He aquí la razón profunda por la cual TD frecuentemente supera a MC en eficiencia muestral.


Ejemplo numérico: random walk de Sutton & Barto

Entorno. Cadena de 7 estados: A, B, C, D, E interiores; dos estados terminales en los extremos. Política aleatoria uniforme entre {izquierda, derecha}. Recompensa $+1$ al alcanzar el terminal derecho, 0 en otro caso. $\gamma = 1$.



Valor verdadero: $V^\pi(A) = 1/6$, $V^\pi(B) = 2/6$, $V^\pi(C) = 3/6$, $V^\pi(D) = 4/6$, $V^\pi(E) = 5/6$. Estos valores constituyen el patrón contra el cual mediremos el error de ambos métodos en el cuaderno.

Random walk: error RMS empírico (lectura cualitativa)



Lectura. TD(0) reduce el error con más rapidez bajo pasos moderados; MC arroja una pendiente menor inicialmente y queda por debajo solo con muchos episodios. El cuaderno de la Clase 3 reproduce con exactitud la figura 6.2 de Sutton & Barto.

Síntesis conceptual: tres ejes ortogonales

La literatura organiza los métodos de RL libres de modelo en torno a tres dimensiones:

1. **Profundidad de la actualización**: ¿se utiliza una sola transición (TD), n pasos ($TD(\lambda)$) o el episodio completo (MC)?
2. **Bootstrapping**: ¿se aprende sobre la base de otras estimaciones?
3. **Muestreo**: ¿se estima la esperanza con muestras o se calcula exactamente mediante el modelo?

Mapa de cuatro cuadrantes (Sutton & Barto, fig. 8.11)

	Profundidad somera	Profundidad plena
No bootstrap, muestreo	—	Monte Carlo
Bootstrap, muestreo	TD(0), SARSA, Q-Learning	TD(λ) con $\lambda < 1$
Bootstrap, sin muestreo	DP (eval. por iteración)	DP completa

Trabajo práctico, anticipo y bibliografía

Contenidos previstos (Python y R en paralelo):

1. Implementación de `first_visit_mc_prediction` y `every_visit_mc_prediction` en GridWorld estocástico.
2. Implementación de `td0_prediction` sobre el mismo entorno.
3. Réplica numérica del random walk de 5 estados: convergencia comparada.
4. Análisis del impacto del paso α : barrido sobre $\alpha \in \{0.01, 0.05, 0.1, 0.2\}$.
5. Estimación de varianza de los métodos a partir de $N = 500$ corridas con bandas de confianza al 95%.
6. Visualización de $\hat{V}$ sobre GridWorld y mapas de error respecto al valor verdadero.

Versión R

Cuaderno paralelo en R Markdown empleando el paquete `ReinforcementLearning` y rutinas tabulares propias, sobre el entorno conda `rl-docencia` vía `reticulate`. Mismas figuras, misma lógica.

Ejercicios propuestos

1. **Ejercicio teórico 1.** Demuestre que el estimador first-visit MC del valor de un estado s es insesgado. Identifique con precisión la fuente de aleatoriedad implicada en la esperanza.
2. **Ejercicio teórico 2.** Pruebe que la actualización TD(0) con pasos $\alpha_n(s)$ que verifican Robbins-Monro converge en esperanza al punto fijo V^π . (Sugerencia: trate la actualización como un esquema estocástico sobre el operador $\mathcal{T}^\pi$ y emplee el lema de Robbins-Siegmund.)
3. **Ejercicio computacional 1.** Reproduzca la figura 6.2 de Sutton & Barto: error RMS de MC y TD(0) sobre el random walk de 5 estados como función del número de episodios, promediando sobre $N = 100$ corridas.
4. **Ejercicio computacional 2.** Compare empíricamente la sensibilidad de MC y TD(0) al paso α . ¿Hay un α^* que minimice el error RMS asintótico? Documente sus hallazgos con figuras y comentarios.
5. **Ejercicio integrador.** Modifique GridWorld para introducir transiciones estocásticas (probabilidad 0.1 de resbalar a un vecino distinto). Compare la convergencia de MC y TD(0) bajo esta dinámica y discuta los resultados a la luz del compromiso sesgo-varianza.

Lo que viene en la Clase 4

Habiendo aprendido a *evaluar* una política sin modelo, la cuestión que sigue es ineludible:

Pregunta central del 26 de mayo

¿Cómo *mejorar* la política mientras la estamos evaluando, en ausencia total de modelo?

Contenidos centrales de la próxima semana:

- Iteración de política generalizada: el motor común detrás del control.
- Algoritmo SARSA: control on-policy basado en TD.
- Algoritmo Q-Learning: control off-policy y convergencia hacia el óptimo.
- Exploración ϵ -greedy aplicada al control, recogiendo las ideas de la Clase 2.
- Comparación SARSA vs. Q-Learning sobre Cliff Walking y GridWorld estocástico.

El TD-error que hoy hemos definido constituirá el eje algorítmico de toda la Clase 4.

Para esta semana: trabajo entre encuentros

Tareas asincrónicas (no entregables):

1. Lectura: Sutton & Barto, Capítulo 5 (secciones 5.1 a 5.4) y Capítulo 6 (secciones 6.1 a 6.3).
2. Ejecución del cuaderno Clase03_MC_TD0.ipynb en Python o R.
3. Reproducción del random walk: figura del error RMS.

Entrega evaluativa (Unidad 2 – primer componente):

Plazo: 25 de mayo, 23:59 hs

Resolver los ejercicios teóricos 1 y 2 más el ejercicio computacional 1. Entregar vía aula virtual en PDF más notebook ejecutado. Constituye el primer componente de las entregas de la Unidad 2 (predicción).

Foro abierto: dudas sobre derivaciones, demostraciones intermedias o detalles de implementación deben canalizarse mediante el foro específico de la Clase 3.

- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2.^a ed.). MIT Press.
 - **Capítulo 5**, secciones 5.1, 5.2, 5.3 y 5.5 (predicción Monte Carlo, exploring starts, importance sampling como anticipo).
 - **Capítulo 6**, secciones 6.1, 6.2 y 6.3 (TD prediction, ventajas de TD, optimalidad de TD(0)).
- Zhao, S. (2024). *Mathematical Foundations of Reinforcement Learning*. Springer.
 - **Capítulo 5** (Monte Carlo): definiciones formales y propiedades estadísticas.
 - **Capítulo 7**, secciones 7.1 a 7.3 (TD learning y aproximación estocástica del operador de Bellman).

Lectura complementaria

Profundización teórica

- Bertsekas, D. P. (2019). *Reinforcement Learning and Optimal Control*. Athena Scientific. Capítulo 4, secciones 4.2 y 4.3 (métodos basados en simulación, contracción estocástica).
- Agarwal, A., Jiang, N., Kakade, S. M., & Sun, W. (2022). *Reinforcement Learning: Theory and Algorithms*. Capítulo 5 (predicción y TD learning, cotas de muestreo).
- Murphy, K. P. (2024). *Probabilistic Machine Learning: Advanced Topics*. MIT Press. Sección 35.3 (métodos Monte Carlo y TD).

Material aplicado

- Lapan, M. (2024). *Deep Reinforcement Learning Hands-On* (3.^a ed.). Packt. Capítulo 5 (implementación de MC y TD sobre Gymnasium).
- Géron, A. (2023). *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow* (3.^a ed.). Capítulo 18 (introducción tabular a RL).
- Graesser, L., & Keng, W. L. (2019). *Foundations of Deep Reinforcement Learning*. Capítulo 3 (predicción y TD desde la perspectiva de implementación).

Lectura clásica recomendada. Sutton, R. S. (1988). Learning to predict by the methods of temporal differences. *Machine Learning*, 3(1), 9–44.

Hasta la próxima semana

Clase 4 – SARSA, Q-Learning y exploración ϵ -greedy

26 de mayo de 2026, 18 a 21 hs

“El aprendizaje verdaderamente útil no aguarda al fin del camino para corregir el rumbo: corrige a cada paso, atento a lo que la experiencia susurra.”