

Aprendizaje por Refuerzo

Fundamentos y Aplicaciones

Clase 4 – SARSA, Q-Learning y exploración ϵ -greedy

Dr. Darío Ezequiel Díaz

26 de mayo de 2026

Facultad de Ingeniería – Posgrados
Universidad Austral

Hoja de ruta del encuentro

- Recapitulación de la Clase 3 y puente hacia el control
- Del problema de predicción al problema de control libre de modelo
- Exploración frente a explotación: la estrategia ϵ -greedy
- SARSA: control *on-policy*
- Q-Learning: control *off-policy*
- SARSA frente a Q-Learning: el precipicio de Sutton & Barto
- Hacia la aproximación de funciones y el anticipo de la Clase 5
- Trabajo práctico, anticipo y bibliografía

Recapitulación y puente conceptual

Lo que consolidamos la semana pasada

Predicción libre de modelo

- **Monte Carlo**: promedio de retornos completos G_t ; insesgado, alta varianza.
- **TD(0)**: actualización por transición mediante *bootstrapping*.

La actualización TD(0)

$$V(S_t) \leftarrow V(S_t) + \alpha \delta_t,$$

$$\delta_t = R_{t+1} + \gamma V(S_{t+1}) - V(S_t).$$

Ambos métodos resolvían el problema de **predicción**: estimar V^π para una política *dada*. Hoy abordamos el problema verdaderamente ambicioso, el del **control**: hallar una política *óptima*.

Sutton & Barto (2018), capítulo 6, secciones 6.1 a 6.3; Zhao (2024), capítulo 7, secciones 7.1 y 7.2.

Del problema de predicción al de control

Conviene distinguir con nitidez las dos tareas fundamentales que articulan toda la teoría:

Predicción (evaluación)

Dada una política π fija, estimar su función de valor:

$$V^\pi(s), \quad Q^\pi(s, a).$$

Es una pregunta *descriptiva*: ¿cuán buena resulta esta conducta?

Control (optimización)

Hallar la política que maximiza el retorno esperado:

$$\pi_* = \arg \max_{\pi} V^\pi(s) \quad \forall s.$$

Es una pregunta *prescriptiva*: ¿cómo debería actuar el agente?

El control no se contenta con juzgar una conducta; persigue **mejorarla** iterativamente hasta la optimalidad.


El esquema que lo unifica: GPI

Iteración de política generalizada (*Generalized Policy Iteration*)

Casi todo método de control en RL admite lectura como la danza de dos procesos que se persiguen mutuamente:

1. **Evaluación**: hacer que la estimación de valor se aproxime a la de la política actual, $Q \rightarrow Q^\pi$.
2. **Mejora**: hacer la política voraz (o casi) respecto de la estimación de valor, $\pi \rightarrow \text{greedy}(Q)$.

El punto fijo conjunto de ambos procesos es la **optimalidad**: cuando la política ya es voraz respecto de su propio valor, nada cambia y se ha alcanzado π_* .



Sutton & Barto (2018), secciones 4.6 y 5.3; Zhao (2024), capítulo 5.

Control libre de modelo y exploración

¿Por qué Q y no V ?

En la programación dinámica, la mejora voraz exigía mirar un paso hacia adelante:

$$\pi'(s) = \arg \max_a \sum_{s'} P(s' | s, a) [R(s, a) + \gamma V(s')].$$

El obstáculo decisivo

Sin modelo, desconocemos $P(s' | s, a)$ y $R(s, a)$. La fórmula anterior resulta inservible: no podemos ponderar los sucesores porque ignoramos su probabilidad.

La salida es elegante. Si estimamos directamente la función de valor de acción $Q(s, a)$, la mejora voraz se torna puramente local:

$$\pi'(s) = \arg \max_a Q(s, a),$$

sin referencia alguna a la dinámica. He aquí la razón profunda por la que el control libre de modelo gravita en torno a Q , no a V .

La tentación de la voracidad pura

Supongamos que actuáramos siempre de forma estrictamente voraz,
 $\pi(s) = \arg \max_a Q(s, a)$, desde el inicio del aprendizaje.

El peligro

Las estimaciones iniciales de Q son arbitrarias y ruidosas. Una acción genuinamente óptima que, por azar, recibió un retorno temprano desfavorable quedaría **condenada al ostracismo**: jamás se la volvería a elegir, y su valor jamás se corregiría.

El agente quedaría atrapado en un óptimo local de su propia ignorancia. La exploración no es un lujo, sino una **condición necesaria** para la convergencia: todo par estado-acción relevante debe visitarse con probabilidad positiva, indefinidamente.

La estrategia ϵ -greedy

El compromiso más sencillo y difundido entre explorar y explotar:

$$\pi(a | s) = \begin{cases} 1 - \epsilon + \frac{\epsilon}{|\mathcal{A}(s)|}, & \text{si } a = \arg \max_{a'} Q(s, a'), \\ \frac{\epsilon}{|\mathcal{A}(s)|}, & \text{en otro caso.} \end{cases}$$

Lectura

Con probabilidad $1 - \epsilon$ se explota (acción voraz); con probabilidad ϵ se explora una acción uniformemente al azar.

Propiedad clave

Es una política **ϵ -soft**: $\pi(a | s) \geq \frac{\epsilon}{|\mathcal{A}(s)|} > 0$ para toda acción. Ninguna acción se extingue.

La condición GLIE: explorar hoy, optimizar mañana

Una exploración constante impediría converger a la política óptima determinista. La solución consiste en **decaer** la exploración con cuidado.

Greedy in the Limit with Infinite Exploration (GLIE)

1. Todo par (s, a) se visita un número infinito de veces: $\lim_{k \rightarrow \infty} N_k(s, a) = \infty$.
2. La política converge a la voraz: $\lim_{k \rightarrow \infty} \pi_k(a | s) = \mathbf{1} \left[a = \arg \max_{a'} Q_k(s, a') \right]$.

Una receta clásica que satisface GLIE es el decaimiento armónico $\epsilon_k = 1/k$: explora con generosidad al comienzo y se vuelve asintóticamente voraz. Esta condición será una de las dos piezas que garantizan la convergencia de SARSA.

Singh, Jaakkola, Littman & Szepesvári (2000); Sutton & Barto (2018), sección 5.4.

El teorema de mejora para políticas ε -greedy

Cabe la inquietud: si la política conserva ruido aleatorio, ¿mejora de veras al volverse ε -greedy respecto de Q^π ?

Resultado (Sutton & Barto, sección 5.4)

Sea π una política ε -soft cualquiera y sea π' la política ε -greedy respecto de Q^π . Entonces π' no es peor que π :

$$V^{\pi'}(s) \geq V^\pi(s) \quad \forall s \in \mathcal{S}.$$

La demostración descansa en verificar que $Q^\pi(s, \pi'(s)) \geq V^\pi(s)$ y aplicar luego el teorema de mejora de política. El mensaje es tranquilizador: dentro del universo de las políticas ε -soft, la voracidad parcial **sí progresa** hacia el óptimo. La igualdad se alcanza precisamente cuando π ya es la mejor política ε -soft posible.

SARSA: control on-policy

La tupla que da nombre al método

El quinteto SARSA

Cada actualización emplea la experiencia de una transición completa con su acción consecuente:

$$(\underbrace{S_t}_{\text{estado}}, \underbrace{A_t}_{\text{acción}}, \underbrace{R_{t+1}}_{\text{recompensa}}, \underbrace{S_{t+1}}_{\text{estado'}}, \underbrace{A_{t+1}}_{\text{acción'}}).$$

El acrónimo **S-A-R-S-A** retrata literalmente la quintupla. El método fue propuesto por Rummerly y Niranjan en 1994 bajo el nombre, hoy en desuso, de *Modified Connectionist Q-Learning*; fue Rich Sutton quien acuñó la denominación memorable que prevaleció.

Rummerly & Niranjan (1994); Sutton & Barto (2018), sección 6.4.

La actualización SARSA

Transportamos la lógica de TD(0) desde V hacia Q . El objetivo de aprendizaje incorpora la acción *efectivamente seleccionada* en el estado sucesor:

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t) \right]$$

El error TD de acción

$$\delta_t = R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t).$$

Mide la discrepancia entre la estimación actual y el objetivo *bootstrap*.

Anclaje teórico

Es una aproximación estocástica del operador de Bellman *para la política* π : el sucesor $A_{t+1} \sim \pi$.

Algoritmo 1 SARSA — control *on-policy* para estimar q_*

- 1: **Entrada:** paso $\alpha \in (0, 1]$, exploración $\varepsilon > 0$ (con decaimiento GLIE).
 - 2: **Inicializar** $Q(s, a)$ de forma arbitraria $\forall s, a$; $Q(\text{terminal}, \cdot) = 0$.
 - 3: **for** cada episodio **do**
 - 4: Inicializar S ; elegir A desde S con política ε -greedy derivada de Q .
 - 5: **for** cada paso del episodio, hasta que S sea terminal **do**
 - 6: Ejecutar A ; observar recompensa R y estado sucesor S' .
 - 7: Elegir A' desde S' con política ε -greedy derivada de Q .
 - 8: $Q(S, A) \leftarrow Q(S, A) + \alpha[R + \gamma Q(S', A') - Q(S, A)]$.
 - 9: $S \leftarrow S'$; $A \leftarrow A'$.
-

¿Qué significa que SARSA sea *on-policy*?

La marca distintiva

SARSA aprende el valor de la **misma política que utiliza para comportarse**, exploración incluida. La acción A_{t+1} que figura en el objetivo es la que la política ϵ -greedy realmente elegirá.

Hay aquí una consecuencia conductual profunda y a menudo deseable: como el objetivo computa el valor *teniendo en cuenta que el agente a veces explorará al azar*, SARSA aprende a ser **prudente**. Internaliza el costo esperado de los pasos exploratorios y, en presencia de regiones peligrosas, prefiere trayectorias con margen de seguridad. Lo veremos con elocuencia en el ejemplo del precipicio.

Convergencia de SARSA

Teorema (Singh, Jaakkola, Littman & Szepesvári, 2000)

SARSA converge con probabilidad uno a la función de valor de acción óptima q_* y a una política voraz óptima, siempre que se cumplan dos familias de condiciones:

1. La política de comportamiento es **GLIE** (exploración infinita que se desvanece hacia la voracidad).
2. Los pasos satisfacen las condiciones de **Robbins-Monro**:

$$\sum_{n=1}^{\infty} \alpha_n(s, a) = \infty, \quad \sum_{n=1}^{\infty} \alpha_n^2(s, a) < \infty.$$

La primera condición asegura cobertura y eventual optimalidad; la segunda equilibra el dilema entre avanzar lo suficiente y amortiguar el ruido del muestreo. Ambas son las herederas directas de la teoría de aproximación estocástica que cimentó TD(0).

Q-Learning: control off-policy

La audacia de Watkins (1989)

SARSA aprende el valor de la política que ejecuta. Christopher Watkins propuso, en su tesis doctoral, una idea más ambiciosa.

La pregunta de Watkins

¿Y si, en lugar de aprender el valor de la política *actual*, aprendiéramos directamente el valor de la política *óptima*, sin importar cómo nos comportemos mientras tanto?

El punto de partida es la **ecuación de optimalidad de Bellman** para q_* :

$$q_*(s, a) = \mathbb{E} \left[R_{t+1} + \gamma \max_{a'} q_*(S_{t+1}, a') \mid S_t = s, A_t = a \right].$$

Repárese en el $\max$: aparece la política voraz, no la de comportamiento.

Watkins (1989); Sutton & Barto (2018), sección 6.5.

La actualización Q-Learning

Una única, decisiva, sustitución frente a SARSA: el sucesor $\gamma Q(S_{t+1}, A_{t+1})$ cede su lugar al máximo sobre las acciones.

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t) \right]$$

SARSA

objetivo = $R + \gamma Q(S', A')$, $A' \sim \pi$.

El sucesor lo dicta la política.

Q-Learning

objetivo = $R + \gamma \max_a Q(S', a)$.

El sucesor lo dicta la voracidad.

Esa $\max$, en apariencia inocua, transforma la naturaleza del método: lo vuelve **off-policy**.

Algoritmo: Q-Learning

Algoritmo 2 Q-Learning — control *off-policy* para estimar q_*

```
1: Entrada: paso  $\alpha \in (0, 1]$ , exploración  $\varepsilon > 0$ .  
2: Inicializar  $Q(s, a)$  de forma arbitraria  $\forall s, a$ ;  $Q(\text{terminal}, \cdot) = 0$ .  
3: for cada episodio do  
4:   Inicializar  $S$ .  
5:   for cada paso del episodio, hasta que  $S$  sea terminal do  
6:     Elegir  $A$  desde  $S$  con política  $\varepsilon$ -greedy derivada de  $Q$ .  
7:     Ejecutar  $A$ ; observar recompensa  $R$  y estado sucesor  $S'$ .  
8:      $Q(S, A) \leftarrow Q(S, A) + \alpha[R + \gamma \max_a Q(S', a) - Q(S, A)]$ .  
9:    $S \leftarrow S'$ .
```

Adviértase que no se requiere elegir A' : el objetivo no depende de la próxima acción ejecutada.

¿Qué significa que Q-Learning sea *off-policy*?

Conviven dos políticas, conceptualmente separadas:

Política de comportamiento

La que **genera la experiencia**: típicamente ϵ -greedy. Garantiza la exploración necesaria para visitar todos los pares.

Política objetivo

La que se **aprende y evalúa**: la voraz respecto de Q , codificada por el operador $\max$ en el objetivo.

Q-Learning aprende el valor de la política *óptima* mientras se comporta según una política *exploratoria*. Esta disociación confiere una flexibilidad notable: el agente puede aprender de datos generados por cualquier política suficientemente exploradora, incluso por demostraciones humanas o experiencias almacenadas, semilla conceptual del *experience replay* que reaparecerá en DQN.

Convergencia de Q-Learning

Teorema (Watkins & Dayan, 1992)

Q-Learning converge con probabilidad uno a q_* siempre que:

1. Todo par (s, a) se visite un número infinito de veces.
2. Los pasos satisfagan las condiciones de Robbins-Monro: $\sum_n \alpha_n = \infty$, $\sum_n \alpha_n^2 < \infty$.

Una diferencia conceptual sutil pero importante

Obsérvese que **no se exige** que la política de comportamiento converja a la voraz, a diferencia de SARSA. Basta con que explore lo suficiente. La política objetivo, fijada por el max, ya es óptima por construcción.

Un puente entre ambos: SARSA esperado

¿Puede mitigarse la varianza del sucesor aleatorio de SARSA sin adoptar el $\max$ de Q-Learning? Sí: tomando la esperanza bajo la política.

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \sum_a \pi(a | S_{t+1}) Q(S_{t+1}, a) - Q(S_t, A_t) \right].$$

Lectura unificadora

- Si π es la propia política ϵ -greedy: es *Expected SARSA*, que elimina la varianza debida a la selección aleatoria de A_{t+1} .
- Si π es la política voraz: la suma colapsa al $\max$ y recuperamos Q-Learning.

SARSA, Expected SARSA y Q-Learning se revelan así como un **continuo**, gobernado por la política respecto de la cual se toma la esperanza del sucesor.

Sutton & Barto (2018), sección 6.6; Zhao (2024), sección 7.4.

SARSA frente a Q-Learning

El precipicio: la ilustración canónica

Cliff Walking (Sutton & Barto, ejemplo 6.6)

Una rejilla. El agente parte de S y debe alcanzar la meta G . Bordeando el borde inferior se extiende un **precipicio**: caer en él acarrea una recompensa de -100 y un regreso forzoso al inicio. Cada paso ordinario cuesta -1 .



— ruta segura (SARSA) — ruta óptima (Q-Learning)

Por qué SARSA y Q-Learning eligen rutas distintas

Q-Learning aprende la ruta óptima

Como evalúa la política *voraz*, descubre que el camino más corto bordea el precipicio. Esa es, en efecto, la trayectoria de máximo retorno **si se la sigue sin error**.

SARSA aprende la ruta segura

Como evalúa su política *exploratoria*, contabiliza que, con probabilidad ϵ , un paso al azar junto al borde precipita la caída. Penaliza esa vecindad y se aleja.

La paradoja del rendimiento en línea

Durante el aprendizaje con ϵ fijo, SARSA obtiene un **retorno por episodio superior**: cae al precipicio mucho menos. Q-Learning, aunque conoce la política óptima, se despeña a menudo por culpa de sus propios pasos exploratorios. Si ϵ decae hacia cero, ambos convergen a la ruta óptima.

El sesgo de maximización

El operador $\max$ de Q-Learning, tan poderoso, oculta un vicio estadístico que conviene conocer.

El fenómeno

Estimar el valor de la mejor acción tomando el máximo de estimaciones *ruidosas* produce, por la desigualdad de Jensen, una **sobreestimación sistemática**:

$$\mathbb{E}\left[\max_a Q(s, a)\right] \geq \max_a \mathbb{E}[Q(s, a)].$$

El máximo de variables aleatorias con error captura, sin querer, el ruido favorable: tiende a coronar la acción que tuvo suerte en el muestreo, no necesariamente la mejor. El remedio clásico es el **doble Q-Learning** (van Hasselt, 2010), que desacopla la selección de la acción de la evaluación de su valor empleando dos estimadores. Este principio será central cuando lleguemos a las variantes profundas en la Clase 5.

Cuadro comparativo

Criterio	SARSA	Q-Learning
Naturaleza	<i>On-policy</i>	<i>Off-policy</i>
Objetivo de aprendizaje	$R + \gamma Q(S', A')$	$R + \gamma \max_a Q(S', a)$
Sucesor en el objetivo	Acción ejecutada $A' \sim \pi$	Acción voraz
Política que evalúa	La de comportamiento	La óptima
Conducta aprendida	Prudente (segura)	Óptima (arriesgada)
Sesgo de maximización	No lo padece	Sí lo padece
Rendimiento en línea (ϵ fijo)	Superior	Inferior
Convergencia a q_*	GLIE + Robbins-Monro	Visitas ∞ + Robbins-Monro
Generalización profunda	Deep SARSA	DQN (Clase 5)

La elección no es dogmática: depende de si interesa el desempeño durante el aprendizaje o la política final, y de la peligrosidad del entorno.

Hacia la aproximación de funciones

La maldición de la dimensionalidad

Cuanto hemos construido reposa sobre una tabla $Q(s, a)$ con una entrada por cada par estado-acción. Esa premisa se desmorona en problemas realistas.

El muro combinatorio

- *Backgammon*: del orden de 10^{20} estados.
- *Go*: más de 10^{170} configuraciones legales.
- Estados **continuos** (posición, velocidad, ángulo en CartPole): cardinalidad infinita; la tabla ni siquiera es definible.

Tabular significa, además, que aprender el valor de un estado **nada enseña** sobre estados vecinos parecidos. Carecemos de generalización. Se impone reemplazar la tabla por una **función parametrizada**.

De la tabla a la aproximación de funciones

Sustituimos la tabla por un aproximador $\hat{q}(s, a; \mathbf{w})$ gobernado por un vector de parámetros $\mathbf{w} \in \mathbb{R}^d$, con $d \ll |\mathcal{S}| \times |\mathcal{A}|$.

SARSA semigradiente (versión episódica)

El aprendizaje se vuelve un descenso de gradiente estocástico sobre el error TD:

$$\mathbf{w} \leftarrow \mathbf{w} + \alpha \left[R + \gamma \hat{q}(S', A'; \mathbf{w}) - \hat{q}(S, A; \mathbf{w}) \right] \nabla_{\mathbf{w}} \hat{q}(S, A; \mathbf{w}).$$

Se lo denomina **semigradiente** porque el objetivo *también* depende de $\mathbf{w}$ a través del *bootstrap*, pero no derivamos a través de él. Con aproximadores lineales y en el régimen on-policy persisten garantías razonables; al combinar aproximación, *bootstrapping* y muestreo off-policy emerge la temida **tríada mortal**, donde la convergencia ya no está asegurada.

Sutton & Barto (2018), capítulos 9 y 10 (sección 10.1); Zhao (2024), capítulo 8.

Anticipo: el salto a DQN

La síntesis de Q-Learning con redes neuronales profundas como aproximador de $\hat{q}$ inaugura el **aprendizaje por refuerzo profundo**.

Los dos artificios de DQN

- *Experience replay*: romper la correlación temporal de los datos.
- *Red objetivo*: estabilizar el blanco *bootstrap*.

Hilo conductor

DQN **es** Q-Learning off-policy con $\hat{q}(s, a; \mathbf{w})$ neuronal; el doble Q-Learning reaparece como *Double DQN*. Nada de lo de hoy queda atrás.

En la práctica de la Clase 5 abandonaremos GridWorld por CartPole y dejaremos que una red aprenda a equilibrar el péndulo. Los fundamentos tabulares de esta clase serán el andamiaje conceptual de todo lo que sigue.

Trabajo práctico, anticipo y bibliografía

Cuaderno Clase04_SARSA_QLearning

- Implementación tabular de SARSA y Q-Learning en un **GridWorld** con precipicio, replicando el ejemplo 6.6.
- Comparación empírica de las trayectorias aprendidas y de las curvas de retorno por episodio.
- Estudio del efecto de ϵ y de su decaimiento sobre la política final.
- Primer contacto con **CartPole** (Gymnasium) como antesala de la aproximación de funciones.

Disponible en Python (sobre Gymnasium) y en R (mediante **reticulate** y el entorno **rl-docencia**), con badges de Google Colab y paridad numérica donde los generadores lo permitan.

Ejercicios propuestos

1. **Ejercicio teórico 1.** Demuestre el teorema de mejora para políticas ϵ -greedy: si π' es ϵ -greedy respecto de Q^π , entonces $Q^\pi(s, \pi'(s)) \geq V^\pi(s)$.
2. **Ejercicio teórico 2.** Exhiba la sustitución exacta de la política π que reduce la actualización de Expected SARSA a la de Q-Learning, y discuta por qué ello revela su carácter off-policy.
3. **Ejercicio computacional 1.** Reproduzca la figura del precipicio (Sutton & Barto, ejemplo 6.6): retorno por episodio de SARSA y Q-Learning con $\epsilon = 0,1$, promediado sobre $N = 500$ corridas.
4. **Ejercicio computacional 2.** Cuantifique empíricamente el sesgo de maximización en un MDP pequeño y verifique la mejora que aporta el doble Q-Learning.
5. **Ejercicio integrador.** Estudie cómo el decaimiento $\epsilon_k = 1/k$ aproxima ambas políticas a la ruta óptima, y contraste con ϵ constante.

Para esta semana: trabajo entre encuentros

Tareas asincrónicas (no entregables):

1. Lectura: Sutton & Barto, capítulo 6, secciones 6.4 a 6.7.
2. Ejecución del cuaderno `Clase04_SARSA_QLearning` en Python o R.
3. Reproducción de la figura del precipicio.

Entrega evaluativa (Unidad 3 — componente de control):

Plazo: 1 de junio, 23:59 hs

Resolver los ejercicios teóricos 1 y 2 más el ejercicio computacional 1. Entregar vía aula virtual en PDF más el *notebook* ejecutado. Constituye el componente de control de la Unidad 3.

Foro abierto: dudas sobre derivaciones, el carácter on/off-policy o detalles de implementación deben canalizarse mediante el foro específico de la Clase 4.

Bibliografía obligatoria de la Clase 4

- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2.^a ed.). MIT Press.
 - **Capítulo 6**, secciones 6.4 (Sarsa), 6.5 (Q-learning, ejemplo 6.6 *Cliff Walking*), 6.6 (Expected Sarsa) y 6.7 (sesgo de maximización y doble aprendizaje).
 - **Sección 5.4** (control con políticas ϵ -soft y teorema de mejora).
- Zhao, S. (2024). *Mathematical Foundations of Reinforcement Learning*. Springer.
 - **Capítulo 7**, secciones 7.2 (Sarsa), 7.3 (Q-learning) y 7.4 (visión unificada).

Profundización teórica

- Watkins, C. J. C. H., & Dayan, P. (1992). Q-learning. *Machine Learning*, 8(3), 279–292.
- Singh, S., Jaakkola, T., Littman, M. L., & Szepesvári, C. (2000). Convergence results for single-step on-policy reinforcement-learning algorithms. *Machine Learning*, 38(3), 287–308.
- van Hasselt, H. (2010). Double Q-learning. *Advances in Neural Information Processing Systems*, 23.
- Bertsekas, D. P. (2019). *Reinforcement Learning and Optimal Control*. Athena Scientific. Capítulo 5 (métodos basados en simulación y aproximación).
- Agarwal, A., Jiang, N., Kakade, S. M., & Sun, W. (2022). *Reinforcement Learning: Theory and Algorithms*. Capítulo sobre Q-learning y complejidad muestral.

Material aplicado

- Lapan, M. (2024). *Deep Reinforcement Learning Hands-On* (3.^a ed.). Packt. Capítulos sobre Q-learning tabular y DQN.
- Graesser, L., & Keng, W. L. (2019). *Foundations of Deep Reinforcement Learning*. Capítulo 3 (SARSA) y capítulo 4 (Q-learning).
- Géron, A. (2023). *Hands-On Machine Learning* (3.^a ed.). Capítulo 18 (Q-learning y DQN).

Hasta la próxima semana

Clase 5 — Aproximación de funciones, DQN y *Policy Gradients*

2 de junio de 2026, 18 a 21 hs

“El verdadero arte del control no consiste en hallar la mejor ruta sobre el papel, sino en aprender a recorrerla cuando el azar gobierna cada paso.”