

Aprendizaje por Refuerzo

Fundamentos y Aplicaciones

Clase 5 — Aproximación de funciones, DQN y *Policy Gradients*

Dr. Darío Ezequiel Díaz

2 de junio de 2026

Facultad de Ingeniería – Posgrados
Universidad Austral

Hoja de ruta del encuentro

- Recapitulación de la Clase 4 y el límite de lo tabular
- De la tabla a la **aproximación de funciones**: el cierre de la Unidad 3
- **Deep Q-Networks** (DQN): repetición de experiencia y red objetivo
- El sesgo de maximización reaparece: *Double DQN* y la familia Rainbow
- Un cambio de paradigma: los **métodos de gradiente de política**
- REINFORCE, la varianza y la línea base
- Arquitecturas **actor-crítico**: de A2C a PPO
- Mapa del territorio, aplicaciones contemporáneas y trabajo práctico

De la tabla a la función

Dónde quedamos: el control libre de modelo tabular

La Clase 4 erigió el control sin modelo sobre dos pilares y una tabla.

Lo conquistado

- SARSA: control *on-policy*, conducta prudente.
- Q-Learning: control *off-policy*, política óptima.
- Exploración ε -greedy con decaimiento GLIE.

El supuesto silencioso

Una tabla $Q(s, a)$ con *una casilla por cada par estado-acción*. Memoria y muestreo crecen con $|\mathcal{S}| \times |\mathcal{A}|$.

La actualización de Q-Learning,

$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t)]$, presupone que cada entrada se visita y se corrige de manera **independiente**. Hoy abandonamos esa premisa.

Sutton & Barto (2018), capítulo 6; el puente anticipado al cierre de la Clase 4.

La maldición de la dimensionalidad

Cuanto edificamos reposa sobre una tabla con una entrada por par estado–acción. Esa premisa se desmorona en problemas realistas.

El muro combinatorio

- *Backgammon*: del orden de 10^{20} estados.
- *Go*: más de 10^{170} configuraciones legales.
- Estados **continuos** (posición, velocidad, ángulo en *CartPole*): cardinalidad infinita; la tabla ni siquiera resulta definible.

Hay un segundo defecto, más sutil y quizá más grave: en el régimen tabular, aprender el valor de un estado **nada enseña** sobre estados vecinos semejantes. Se carece de *generalización*. Conviene, pues, reemplazar la tabla por una función parametrizada capaz de interpolar y extrapolar.

De la tabla al aproximador parametrizado

Sustituimos la enorme tabla por una función $\hat{q}(s, a; \mathbf{w})$ regida por un vector de parámetros $\mathbf{w} \in \mathbb{R}^d$, con $d \ll |\mathcal{S}| \times |\mathcal{A}|$.

Una mirada estadística

El problema deviene **regresión**: ajustar $\hat{q}(\cdot; \mathbf{w})$ a un conjunto de objetivos (los retornos o sus estimaciones bootstrap). Los métodos de la teoría de la aproximación funcional —lineales, kernels, redes— quedan disponibles.

El precio a pagar

Modificar $\mathbf{w}$ para corregir un estado *altera el valor de todos los demás*. La actualización deja de ser local; emerge la posibilidad de interferencia.

Esta tensión entre **generalización** (deseable) e **interferencia** (peligrosa) vertebró toda la teoría de la aproximación de funciones en RL.

Sutton & Barto (2018), capítulo 9, sección 9.1; Zhao (2024), capítulo 8.

El objetivo de la predicción: el error de valor cuadrático medio

¿Qué significa que $\hat{v}(s; \mathbf{w})$ sea «buena»? Se mide su discrepancia respecto del valor verdadero v_π , **ponderada** por la frecuencia con que se visita cada estado.

Mean Squared Value Error (VE)

$$\overline{\text{VE}}(\mathbf{w}) = \sum_{s \in \mathcal{S}} \mu(s) [v_\pi(s) - \hat{v}(s; \mathbf{w})]^2,$$

donde $\mu(s) \geq 0$, $\sum_s \mu(s) = 1$, es la distribución *on-policy* (la fracción asintótica de tiempo en s bajo π).

La ponderación μ no es un adorno: declara que importa acertar allí donde el agente efectivamente transita, y tolera el error en los rincones que rara vez visita. He aquí una diferencia conceptual nítida frente a la regresión clásica, donde los pesos suelen ser uniformes.

Sutton & Barto (2018), sección 9.2; en el límite lineal, $\overline{\text{VE}}$ posee un único mínimo global.

Aproximadores lineales y construcción de características

El caso más estudiado expresa el valor como producto interno entre un vector de **características** $\mathbf{x}(s) \in \mathbb{R}^d$ y los pesos:

$$\hat{v}(s; \mathbf{w}) = \mathbf{w}^\top \mathbf{x}(s) = \sum_{i=1}^d w_i x_i(s).$$

Bases clásicas

- Polinomios y bases de Fourier.
- *Tile coding*: rejillas superpuestas y desplazadas.
- Funciones de base radial (RBF).

La virtud lineal

Bajo aproximación lineal y régimen on-policy, el TD semigradiente converge al *punto fijo TD*, con garantías análogas a las de Robbins–Monro.

El ejemplo canónico es *Mountain Car*: el coche subactuado debe **ganar impulso** oscilando; el estado continuo se codifica con *tile coding* y SARSA semigradiente halla la política de balanceo.

Sutton & Barto (2018), secciones 9.4–9.5 y 10.1; Zhao (2024), capítulo 8.

Control con aproximación: SARSA semigradiente

Transportamos la idea al control reemplazando v por $\hat{q}(s, a; \mathbf{w})$. El aprendizaje se vuelve un **descenso de gradiente estocástico** sobre el error TD de acción:

Actualización semigradiente (versión episódica)


$$\mathbf{w} \leftarrow \mathbf{w} + \alpha \left[\underbrace{R_{t+1} + \gamma \hat{q}(S_{t+1}, A_{t+1}; \mathbf{w})}_{\text{objetivo bootstrap}} - \hat{q}(S_t, A_t; \mathbf{w}) \right] \nabla_{\mathbf{w}} \hat{q}(S_t, A_t; \mathbf{w}).$$

Se lo denomina **semi**gradiente por una razón precisa: el objetivo también depende de $\mathbf{w}$ a través del término bootstrap, pero *no derivamos a través de él*. No es, por tanto, el gradiente genuino de ninguna función de error; es una aproximación que conserva, sin embargo, excelentes propiedades en el caso lineal on-policy.

Sutton & Barto (2018), sección 10.1 (Episodic Semi-gradient Sarsa); Zhao (2024), capítulo 8.

La tríada mortal

Tres ingredientes, individualmente inocuos, conspiran al combinarse:



- Aproximación de funciones (necesaria para escalar).
- **Bootstrapping** (TD: eficiente, de baja varianza).
- Muestreo *off-policy* (flexibilidad de Q-Learning).

Con cualesquiera **dos** de los tres, la convergencia suele estar a salvo. Con los **tres** simultáneamente, las estimaciones pueden *divergir* hacia el infinito, aun en problemas lineales diminutos (contraejemplo de Baird).

DQN habita, precisamente, en el vértice peligroso. Su mérito histórico fue domesticar la tríada con dos artificios de ingeniería.

Sutton & Barto (2018), sección 11.3 (*the deadly triad*); contraejemplo de Baird (1995).

Aprendizaje por refuerzo profundo: DQN

De lo lineal a lo profundo

Una red neuronal profunda es un aproximador $\hat{q}(s, a; \mathbf{w})$ **no lineal** y, en principio, universal: con suficiente capacidad, representa funciones de complejidad arbitraria.

La promesa

Aprender las características *en lugar de diseñarlas a mano*. La red destila, capa a capa, representaciones del estado crudo (píxeles, sensores) idóneas para estimar el valor.

La amenaza

Al abandonar la linealidad perdemos las garantías de convergencia. Combinar Q-Learning con una red neuronal reúne los tres vértices de la tríada mortal y, sin cuidados, el entrenamiento *oscila o diverge*.

La pregunta de 2013 fue: ¿puede estabilizarse este matrimonio? La respuesta —afirmativa— abrió la era del RL profundo.

Mnih et al. (2013, 2015); Sutton & Barto (2018), sección 16.5.

Las dos patologías y sus remedios

El entrenamiento ingenuo de una Q-red padece dos males concretos:

Mal 1 — Correlación temporal

Las transiciones consecutivas son fuertemente dependientes. El descenso de gradiente, que presupone datos **i.i.d.**, recibe lotes sesgados y «olvida» lo aprendido en regiones ya abandonadas.



Mal 2 — Blanco móvil

El objetivo $R + \gamma \max_a \hat{q}(S', a; \mathbf{w})$ depende de los *mismos* pesos que se actualizan. Perseguir un blanco que se desplaza con cada paso induce **inestabilidad** y realimentación viciosa.



Artificio 1: repetición de experiencia

Cada transición observada $(S_t, A_t, R_{t+1}, S_{t+1})$ se almacena en una memoria circular $\mathcal{D}$ —el *replay buffer*— de capacidad fija.

Cómo opera

El entrenamiento no consume la última transición, sino un **minilote muestreado al azar** de $\mathcal{D}$. Cada experiencia puede reutilizarse muchas veces.

Qué rompe

El muestreo aleatorio **descorrelaciona** las muestras del lote, aproximando la hipótesis i.i.d. del descenso de gradiente.

Qué exige

Sólo es lícito porque Q-Learning es **off-policy**: aprende de datos generados por políticas pasadas, hoy distintas de la actual.

Repárese en la genealogía: la disociación entre política de comportamiento y política objetivo —vista en la Clase 4— constituye la **condición lógica** que legitima la repetición de experiencia.

Lin (1992); Mnih et al. (2015).

Artificio 2: red objetivo y la pérdida de DQN

Se mantiene una segunda copia de la red, la **red objetivo** de parámetros $\mathbf{w}^-$, que se *congela* y sólo se sincroniza con $\mathbf{w}$ cada C pasos.

La función de pérdida

$$L(\mathbf{w}) = \mathbb{E}_{(s,a,r,s') \sim \mathcal{D}} \left[\underbrace{\left(r + \gamma \max_{a'} \hat{q}(s', a'; \mathbf{w}^-) - \hat{q}(s, a; \mathbf{w}) \right)^2}_{\text{blanco con } \mathbf{w}^- \text{ fijo}} \right].$$

El blanco se calcula con $\mathbf{w}^-$, no con $\mathbf{w}$. Durante C pasos el objetivo permanece **estable**, y el problema se asemeja a una regresión supervisada de blanco fijo: la red en línea persigue un blanco quieto, no uno que huye a cada paso.

En síntesis: **repetición de experiencia** ataca la correlación; **red objetivo** ataca el blanco móvil. Juntas, estabilizan la tríada.

Mnih et al. (2015), *Human-level control through deep reinforcement learning*, Nature.


Algoritmo: Deep Q-Network

DQN — control off-policy con aproximación neuronal

1. Inicializar memoria $\mathcal{D}$; pesos $\mathbf{w}$ al azar; red objetivo $\mathbf{w}^- \leftarrow \mathbf{w}$.
2. **para** cada episodio **hacer**
3. Observar estado inicial s .
4. **para** cada paso **hacer**
5. Elegir a con política ϵ -greedy derivada de $\hat{q}(s, \cdot; \mathbf{w})$.
6. Ejecutar a ; observar r y s' ; almacenar (s, a, r, s') en $\mathcal{D}$.
7. Muestrear un minilote $\{(s_j, a_j, r_j, s'_j)\}$ de $\mathcal{D}$.
8. Fijar $y_j = r_j + \gamma \max_{a'} \hat{q}(s'_j, a'; \mathbf{w}^-)$ (o $y_j = r_j$ si s'_j es terminal).
9. Paso de descenso sobre $\sum_j (y_j - \hat{q}(s_j, a_j; \mathbf{w}))^2$.
10. Cada C pasos: $\mathbf{w}^- \leftarrow \mathbf{w}$. Decaer ϵ .

El esqueleto es Q-Learning; cuanto se añade es la **maquinaria de estabilización**.

La arquitectura: del píxel al valor



Una decisión de diseño elegante

La red recibe *sólo el estado* y emite, en una pasada, el valor de **todas las acciones**. El operador $\max_a$ y la selección ϵ -greedy se resuelven leyendo el vector de salida: un único *forward* por decisión.

El hito de Atari

Mnih et al. (2013, 2015)

Un **único** agente DQN, sin ajustes específicos por juego, aprendió a jugar 49 títulos de Atari 2600 *a partir de los píxeles crudos* y la puntuación, alcanzando o superando el desempeño humano experto en la mayoría.

Tres ingredientes habilitaron el resultado:

- Una red convolucional que percibe la pantalla.
- Repetición de experiencia que estabiliza el aprendizaje.
- Red objetivo que ancla el blanco bootstrap.

Su importancia trasciende lo técnico: demostró que una *misma* arquitectura, con *idénticos* hiperparámetros, podía dominar tareas perceptivamente diversas. Fue el acta de nacimiento del aprendizaje por refuerzo profundo como disciplina.

Mnih et al. (2013), arXiv; Mnih et al. (2015), Nature 518, 529–533.

El sesgo de maximización regresa: Double DQN

Recordemos la lección de la Clase 4: el operador $\max$ sobre estimaciones ruidosas **sobreestima** sistemáticamente, pues $\mathbb{E}[\max_a Q(s, a)] \geq \max_a \mathbb{E}[Q(s, a)]$ (desigualdad de Jensen).

DQN estándar

$$y = r + \gamma \hat{q}(s', \arg \max_{a'} \hat{q}(s', a'; \mathbf{w}^-); \mathbf{w}^-).$$

Un mismo conjunto de pesos **selecciona y evalúa**.

Double DQN

$$y = r + \gamma \hat{q}(s', \arg \max_{a'} \hat{q}(s', a'; \mathbf{w}); \mathbf{w}^-).$$

La red en línea **selecciona**; la red objetivo **evalúa**.

Desacoplar selección y evaluación mitiga el sesgo optimista, casi sin costo computacional. Es el *doble Q-Learning* de van Hasselt (2010), trasladado al régimen profundo. Nada de la Clase 4 quedó atrás: reaparece, vestido de red neuronal.

van Hasselt, Guez & Silver (2016), *Deep RL with Double Q-learning*, AAAI.

La familia de mejoras: hacia Rainbow

Sobre el esqueleto de DQN floreció una colección de refinamientos ortogonales:

Componentes principales

- **Double DQN**: corrige el sesgo de maximización.
- **Prioritized Experience Replay**: muestrea con mayor probabilidad las transiciones de error TD elevado.
- **Dueling networks**: separan el valor de estado $V(s)$ de la ventaja $A(s, a)$ y los recombinan.
- *Multi-step returns, Noisy Nets, Distributional RL (C51).*

El trabajo *Rainbow* (Hessel et al., 2018) demostró que estos componentes son **complementarios**: integrados en un único agente, su efecto se acumula y supera a cada mejora por separado. Una lección metodológica valiosa sobre la composición de ideas.

Wang et al. (2016); Schaul et al. (2016); Bellemare et al. (2017); Hessel et al. (2018), AAAI.

Métodos de gradiente de política

Un cambio de paradigma

Cuanto hemos visto —Q-Learning, DQN— pertenece a la estirpe **basada en valor**: estimar Q y derivar la política por voracidad. Existe una vía radicalmente distinta.

Tres límites del enfoque basado en valor

- Acciones **continuas**: el $\max_a Q(s, a)$ exige una optimización en cada paso, en general intratable.
- Políticas óptimas **estocásticas**: la voracidad sólo produce políticas deterministas, inadecuadas, por ejemplo, en juegos con información imperfecta.
- Discontinuidad: un cambio infinitesimal en Q puede saltar abruptamente la acción voraz.

La alternativa: **parametrizar la política directamente**, $\pi_\theta(a | s)$, y optimizar θ por ascenso de gradiente sobre el rendimiento. El valor, si aparece, será un medio, no un fin.

Sutton & Barto (2018), capítulo 13; Zhao (2024), capítulo 9.

Parametrizar la política

Se elige una familia diferenciable $\pi_\theta(a | s)$, con $\theta \in \mathbb{R}^d$.

Acciones discretas: *softmax*

$$\pi_\theta(a | s) = \frac{e^{h(s,a;\theta)}}{\sum_b e^{h(s,b;\theta)}},$$

con h una preferencia (la salida de una red). Toda acción conserva probabilidad positiva: exploración **intrínseca**.

Acciones continuas: gaussiana

$$\pi_\theta(a | s) = \mathcal{N}(a; \mu_\theta(s), \sigma_\theta^2(s)).$$

La red emite media y dispersión; la acción se muestrea. Natural en control y robótica.

Adviértase una ventaja conceptual: a diferencia de ε -greedy, aquí la exploración **forma parte** de la política y se ajusta con el aprendizaje —puede concentrarse donde conviene y dispersarse donde aún se ignora.

Sutton & Barto (2018), secciones 13.1 y 13.7; Williams (1992).

El teorema del gradiente de política

Definimos el rendimiento como el valor esperado desde el estado inicial, $J(\theta) = \mathbb{E}_{\pi_\theta}[\sum_t \gamma^t R_{t+1}]$, y buscamos $\theta^* = \arg \max_{\theta} J(\theta)$ por ascenso: $\theta \leftarrow \theta + \alpha \nabla_{\theta} J(\theta)$.

Teorema (Sutton et al., 2000)

$$\nabla_{\theta} J(\theta) \propto \mathbb{E}_{\pi_{\theta}}[Q^{\pi_{\theta}}(s, a) \nabla_{\theta} \log \pi_{\theta}(a | s)].$$

El resultado es notable: el gradiente **no contiene** la derivada de la distribución de estados $\mu(s)$, pese a que esta depende de θ . El difícil término que mediría «cómo cambia la frecuencia de visita al mover la política» se cancela. Quedamos con una esperanza **estimable por muestreo**: el factor $\nabla_{\theta} \log \pi_{\theta}$ —la *función de score*— ponderado por el valor de la acción.

Sutton, McAllester, Singh & Mansour (2000), NIPS; Zhao (2024), capítulo 9.

REINFORCE: el gradiente de política de Monte Carlo

Si se sustituye $Q^{\pi_\theta}(s, a)$ por el **retorno muestral** G_t —insesgado por definición de Q — se obtiene el algoritmo seminal.

Actualización REINFORCE

$$\theta \leftarrow \theta + \alpha \gamma^t G_t \nabla_\theta \log \pi_\theta(A_t | S_t).$$

La intuición es transparente y casi conductista: si una acción condujo a un retorno **elevado**, se eleva su log-probabilidad —se la hará más frecuente—; si condujo a un retorno **pobre**, se la reprime. El término $\nabla_\theta \log \pi_\theta$ indica la dirección en el espacio de parámetros que más incrementa la probabilidad de la acción ejecutada.

Como todo método Monte Carlo, REINFORCE es **insesgado** pero padece **alta varianza**: aguarda el retorno completo del episodio y lo emplea sin filtrar.

Williams (1992); Sutton & Barto (2018), sección 13.3.

La varianza y la línea base

La alta varianza de REINFORCE ralentiza y desestabiliza el aprendizaje. El remedio, estadísticamente elegante, es restar una **línea base** $b(s)$ que no dependa de la acción:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}}[(Q^{\pi_{\theta}}(s, a) - b(s)) \nabla_{\theta} \log \pi_{\theta}(a | s)].$$

Por qué es lícito

Como $\mathbb{E}_{a \sim \pi}[b(s) \nabla_{\theta} \log \pi_{\theta}(a | s)] = b(s) \nabla_{\theta} \sum_a \pi_{\theta}(a | s) = 0$, la línea base **no introduce sesgo**.

Por qué conviene

Una elección juiciosa $-b(s) = V(s) -$ **reduce la varianza**. Lo que importa no es el retorno absoluto, sino cuánto *supera* a lo esperado en ese estado.

El término $Q^{\pi}(s, a) - V^{\pi}(s)$ recibe nombre propio: la **ventaja** $A^{\pi}(s, a)$. Mide la bondad *relativa* de una acción. De aquí brota, naturalmente, la idea actor-crítico.

Sutton & Barto (2018), sección 13.4; Greensmith, Bartlett & Baxter (2004).

Arquitecturas actor-crítico y PPO


La síntesis: actor y crítico

Si la línea base ideal es $V(s)$, ¿por qué no **aprenderla** con los métodos de la Clase 3? Surgen así dos componentes acoplados, ambos parametrizados por redes.

- **Actor** $\pi_{\theta}(a | s)$: *decide* qué hacer; se ajusta por gradiente de política.
- **Crítico** $\hat{v}(s; \mathbf{w})$: *evalúa* las decisiones; se ajusta por TD, como en la Clase 3.

El crítico provee una estimación de la ventaja —típicamente el error TD


$\delta_t = R_{t+1} + \gamma \hat{v}(S_{t+1}; \mathbf{w}) - \hat{v}(S_t; \mathbf{w})$, estimador incesgado de A^{π} — que orienta al actor con **baja varianza**.



Konda & Tsitsiklis (2000); Sutton & Barto (2018), sección 13.5; Zhao (2024), capítulo 10.

El espectro sesgo-varianza y la familia A2C/A3C

Actor-crítico ocupa un punto intermedio en un continuo que ya conocemos.



- **A2C** (*Advantage Actor-Critic*): versión sincrónica que estima la ventaja y actualiza por lotes.
- **A3C** (*Asynchronous*): múltiples trabajadores paralelos exploran copias del entorno y descorrelacionan las actualizaciones *sin* memoria de repetición.
- **GAE** (*Generalized Advantage Estimation*): interpola entre TD y Monte Carlo con un parámetro λ , calibrando el compromiso a voluntad.

La elección del horizonte de bootstrap es, en el fondo, una **decisión estadística**: cuánto sesgo tolerar a cambio de cuánta varianza ahorrar.

Mnih et al. (2016), A3C, ICML; Schulman et al. (2016), GAE.

De la región de confianza al recorte: PPO

Un peligro acecha al gradiente de política: un paso **demasiado grande** puede desplomar el rendimiento, y como los datos los genera la propia política, la recuperación es ardua. La cura es limitar cuánto cambia la política por actualización.

TRPO (2015)

Restringe la actualización a una **región de confianza**: la divergencia Kullback–Leibler entre política nueva y vieja no excede un umbral. Riguroso, pero de implementación costosa (optimización con restricción).

PPO (2017)

Captura el mismo espíritu con un objetivo **recortado** de optimización simple, sin restricción explícita. Robusto, eficiente y hoy uno de los algoritmos más empleados en la práctica.

PPO encarna una filosofía pragmática: sacrificar parte del rigor teórico de TRPO a cambio de **simplicidad y estabilidad empírica**, virtudes decisivas en la ingeniería real.

Schulman et al. (2015), TRPO; Schulman et al. (2017), PPO.

El objetivo recortado de PPO

Sea $r_t(\theta) = \frac{\pi_\theta(A_t | S_t)}{\pi_{\theta_{\text{old}}}(A_t | S_t)}$ el cociente de probabilidades y $\hat{A}_t$ la ventaja estimada. PPO maximiza:

Objetivo *clipped*

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right].$$

La lectura del mecanismo:


- Ventaja **positiva**: conviene aumentar r_t , pero el recorte impide que supere $1 + \epsilon$; no se premia en exceso un solo paso.
- Ventaja **negativa**: el recorte por debajo de $1 - \epsilon$ frena un castigo desmedido.
- El **min** toma la cota **pesimista**: salvaguarda frente a actualizaciones temerarias.

Con $\epsilon \approx 0,2$ el cociente se confina cerca de la unidad y la política evoluciona con prudencia.

Schulman et al. (2017), *Proximal Policy Optimization Algorithms*, arXiv.

Síntesis, taxonomía y aplicaciones

Mapa del territorio



Actor-crítico no es un tercer continente, sino el **punto** entre los dos hemisferios: hereda la decisión directa del gradiente de política y la evaluación de bajo ruido de los métodos de valor. La mayoría de los algoritmos modernos habitan ese punto.

Cuadro comparativo

Criterio	DQN	REINFORCE	PPO
Aprende	$Q(s, a)$	$\pi_{\theta}(a s)$	π_{θ} y $\hat{v}$
Naturaleza	Off-policy	On-policy	On-policy
Política	Determinista	Estocástica	Estocástica
Acciones	Discretas	Discr./contin.	Discr./contin.
Varianza	Baja	Alta	Moderada
Eficiencia muestral	Alta (replay)	Baja	Media
Estabilidad	Media	Baja	Alta

No hay un campeón universal: la elección pondera la naturaleza de las acciones, el presupuesto de muestras y la tolerancia a la inestabilidad.

Aplicaciones contemporáneas

El andamiaje de hoy sostiene logros que han trascendido el laboratorio.

Juegos y planificación

AlphaGo / *AlphaZero* combinan redes de valor y de política con búsqueda de Monte Carlo; *AlphaStar* y *OpenAI Five* dominaron juegos de estrategia en tiempo real.

Robótica y control

Locomoción, manipulación diestra y control de plasma en reactores de fusión por confinamiento magnético.

Modelos de lenguaje

El **RLHF** —aprendizaje por refuerzo a partir de retroalimentación humana, con PPO como caballo de batalla— alinea grandes modelos de lenguaje con las preferencias humanas.

Otras fronteras

Sistemas de recomendación, gestión de carteras, optimización de centros de datos y descubrimiento de algoritmos.

Silver et al. (2016, 2017, 2018); Degraeve et al. (2022), *Nature*; Ouyang et al. (2022), InstructGPT.

Práctica, ejercicios y bibliografía

Práctica de hoy: CartPole

Abandonamos *GridWorld* por *CartPole-v1* (Gymnasium): un péndulo invertido sobre un carro, con estado continuo de cuatro dimensiones.

Cuaderno Clase05_DQN_PolicyGradients

- **DQN** sobre CartPole con repetición de experiencia y red objetivo; curvas de retorno y efecto de la sincronización C.
- **REINFORCE** con y sin línea base; visualización de la reducción de varianza.
- Comparación con **PPO** mediante *Stable-Baselines3*.

Disponible en **Python** (Gymnasium + PyTorch + SB3) y en **R** (vía **reticulate** y el entorno **rl-docencia**), con *badges* de Google Colab. La paridad numérica plena cede aquí ante la estocasticidad de la inicialización neuronal; se documenta como oportunidad didáctica sobre reproducibilidad en el aprendizaje profundo.

Repositorio: github.com/DrDarioDiaz/RL_Austral_2026.

Ejercicios propuestos

1. **Teórico 1.** Demuestre que una línea base $b(s)$ independiente de la acción no introduce sesgo en el gradiente de política, partiendo de $\mathbb{E}_{a \sim \pi} [\nabla_{\theta} \log \pi_{\theta}(a | s)] = 0$.
2. **Teórico 2.** Derive la equivalencia entre minimizar la pérdida de DQN con red objetivo fija y un paso de Q-Learning, identificando el papel de $\mathbf{w}^-$.
3. **Computacional 1.** Entrene DQN en CartPole; estudie el efecto de la capacidad del *replay buffer* y de C sobre la estabilidad de la curva de retorno.
4. **Computacional 2.** Implemente REINFORCE con y sin línea base $V(s)$ y cuantifique empíricamente la reducción de varianza del gradiente.
5. **Integrador.** Contraste DQN, REINFORCE y PPO en CartPole bajo idéntico presupuesto de pasos; discuta eficiencia muestral, estabilidad y rendimiento final.

Para esta semana: trabajo entre encuentros

Tareas asincrónicas (no entregables)

1. Lectura: Sutton & Barto, capítulos 9 (secciones 9.1–9.5), 10 (10.1) y 13 (13.1–13.5).
2. Ejecución del cuaderno `Clase05_DQN_PolicyGradients` en Python o R.
3. Reproducción de las curvas de aprendizaje de DQN y REINFORCE en CartPole.

Entrega evaluativa (Unidad 4 — componente de RL profundo)

Plazo: 8 de junio, 23:59 hs. Resolver el ejercicio teórico 1 y el computacional 1, más una de las dos opciones avanzadas (computacional 2 o integrador). Entregar vía aula virtual en PDF junto al notebook ejecutado.

Las dudas sobre derivaciones, estabilización de DQN o el objetivo de PPO deben canalizarse por el foro específico de la Clase 5.

- **Sutton, R. S., & Barto, A. G.** (2018). *Reinforcement Learning: An Introduction* (2.^a ed.). MIT Press.
 - Capítulo 9: predicción on-policy con aproximación (9.1 objetivo VE, 9.3 SGD, 9.4 lineal, 9.5 construcción de características).
 - Capítulo 10, sección 10.1 (SARSA semigradiente episódico); sección 11.3 (la tríada mortal).
 - Capítulo 13: métodos de gradiente de política (13.1–13.5).
 - Capítulo 16, sección 16.5 (DQN y los juegos de Atari).
- **Zhao, S.** (2024). *Mathematical Foundations of Reinforcement Learning*. Springer.
 - Capítulo 8 (aproximación de la función de valor), capítulo 9 (gradiente de política), capítulo 10 (actor-crítico).

Artículos fundacionales

- Mnih, V., et al. (2015). *Human-level control through deep reinforcement learning*. Nature, 518, 529–533.
- van Hasselt, H., Guez, A., & Silver, D. (2016). *Deep reinforcement learning with double Q-learning*. AAAI.
- Hessel, M., et al. (2018). *Rainbow: combining improvements in deep RL*. AAAI.
- Williams, R. J. (1992). *Simple statistical gradient-following algorithms*. Machine Learning, 8, 229–256.
- Schulman, J., et al. (2017). *Proximal policy optimization algorithms*. arXiv:1707.06347.

Material aplicado

- Lapan, M. (2024). *Deep Reinforcement Learning Hands-On* (3.^a ed.). Packt. Capítulos sobre DQN y métodos de política.
- Graesser, L., & Keng, W. L. (2019). *Foundations of Deep Reinforcement Learning*. Capítulos 2–7.
- Géron, A. (2023). *Hands-On Machine Learning* (3.^a ed.). Capítulo 18.

Hasta la próxima semana

Clase 6 — Aplicaciones, integración y RL profundo avanzado

9 de junio de 2026, 18 a 21 hs

*“Quien aprende el valor de cada acción gobierna lo conocido;
quien aprende a obrar directamente se atreve con lo continuo, lo incierto y lo aún no imaginado.”*