

Aprendizaje por Refuerzo Fundamentos y Aplicaciones

Clase 6 — Actor-Crítico, PPO y aplicaciones
contemporáneas

Dr. Darío Ezequiel Díaz

23 de junio de 2026

Facultad de Ingeniería – Posgrados
Universidad Austral

Hoja de ruta del encuentro

- Recapitulación: del *baseline* al crítico
- Métodos actor-crítico: A2C y la ventaja generalizada
- Región de confianza y **PPO**
- DQN avanzado: la familia *Rainbow*
- Ecosistema moderno: Gymnasium y Stable-Baselines3
- Aplicaciones contemporáneas y desafíos abiertos
- Integración: el mapa del curso
- Trabajo final integrador y consultas

Sexto y último encuentro · Unidad 4 e Integración · 18 a 22 hs.

Parte 1

Recapitulación: del *baseline* al crítico

Seis encuentros, una sola arquitectura

Recordemos los peldaños ya recorridos:

- Clase 2. El operador de Bellman T^π , determinista, cuyo punto fijo V^π se obtenía por inversión exacta.
- Clase 3. Monte Carlo y TD(0) como *aproximación estocástica* de Robbins–Monro de ese operador.
- Clase 4. La iteración de política generalizada: SARSA y Q-Learning entrelazando evaluación y mejora.
- Clase 5. La aproximación de funciones $\hat{q}(s, a; \mathbf{w})$ y la doble vía: DQN del lado del valor, REINFORCE del lado de la política.

El hilo de hoy

Las dos vías que la Clase 5 separó vuelven a confluir: el *actor-crítico* no es sino la iteración de política generalizada realizada con redes neuronales y gradiente estocástico.

Las dos ramas de la Clase 5

Rama basada en valor

Aprende $\hat{q}(s, a; \mathbf{w})$; la política se deriva de manera voraz.

$$\mathbf{w} \leftarrow \mathbf{w} + \alpha \delta \nabla_{\mathbf{w}} \hat{q}(s, a; \mathbf{w})$$

Representante: **DQN**.

Naturalmente *off-policy*.

Rama basada en política

Parametriza $\pi(a | s; \boldsymbol{\theta})$ y asciende por el gradiente del retorno esperado.

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha \nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta})$$

Representante: **REINFORCE** con línea base. *On-policy*.

El resultado empírico de la Clase 5

Una línea base redujo la varianza del gradiente entre un 67 % y un 92 % sin alterar su esperanza: es la puerta de entrada al crítico.

La línea base y su límite

El gradiente de política admite, sin sesgo alguno, la sustracción de una función que dependa solo del estado:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi} \left[\nabla_{\theta} \log \pi(A | S; \theta) (G_t - b(S_t)) \right].$$

Por qué la invarianza se sostiene

Dado que

$\mathbb{E}_{A \sim \pi} [\nabla_{\theta} \log \pi(A | S; \theta) b(S)] = b(S) \nabla_{\theta} \sum_a \pi(a | S; \theta) = b(S) \nabla_{\theta} 1 = 0$, la línea base modifica la varianza pero jamás la esperanza.

En REINFORCE, $b(S_t) = \hat{v}(S_t; \mathbf{w})$ cumple un papel puramente pasivo: resta, pero no propaga información temporal. La pregunta natural se impone: **¿y si esa misma estimación de valor se empleara, además, para estimar el retorno?**

Sutton & Barto (2018), §13.4 · Zhao (2024), §10.2.

De la línea base al crítico

La distinción es sutil y decisiva. Reside en una sola palabra: *bootstrapping*.

Línea base

$\hat{v}$ se resta del retorno Monte Carlo G_t . El estimador permanece *insesgado*; converge a un óptimo local, pero aprende con lentitud y elevada varianza.

Crítico

$\hat{v}$ se usa para *bootstrapping*: estima el retorno a partir de su propia predicción. Aparece sesgo, a cambio de operación en línea, incrementalidad y varianza mucho menor.

El precio del crítico

El *bootstrapping* introduce sesgo y una dependencia asintótica de la calidad de la aproximación. Como en toda la Clase 3, se trata de un compromiso sesgo-varianza, no de un dogma.

Parte 2

Métodos actor-crítico

El teorema del gradiente de política

El fundamento que habilita todo lo que sigue establece que el gradiente del retorno esperado prescinde del gradiente de la dinámica:

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) \propto \mathbb{E}_{\pi} \left[\nabla_{\boldsymbol{\theta}} \log \pi(A | S; \boldsymbol{\theta}) q_{\pi}(S, A) \right].$$

Reemplazando q_{π} por la *ventaja* —legítimo por la invarianza de línea base— se obtiene la forma que vertebra los métodos modernos:

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) \propto \mathbb{E}_{\pi} \left[\nabla_{\boldsymbol{\theta}} \log \pi(A | S; \boldsymbol{\theta}) A_{\pi}(S, A) \right], \quad A_{\pi}(s, a) = q_{\pi}(s, a) - v_{\pi}(s).$$

Lectura

El término $\nabla_{\boldsymbol{\theta}} \log \pi$ —la *elegibilidad característica*— señala la dirección que hace más probable la acción; la ventaja A_{π} pondera, por su signo y magnitud, si conviene reforzarla.

Actor-crítico de un paso

Sustituimos el retorno completo de REINFORCE por su versión de un paso, con un crítico aprendido que provee el blanco *bootstrap*. Definido el error TD

$$\delta_t \doteq R_{t+1} + \gamma \hat{v}(S_{t+1}; \mathbf{w}) - \hat{v}(S_t; \mathbf{w}),$$


las dos actualizaciones acopladas son

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t + \alpha^\theta \delta_t \nabla_{\boldsymbol{\theta}} \log \pi(A_t | S_t; \boldsymbol{\theta}_t), \quad \mathbf{w}_{t+1} = \mathbf{w}_t + \alpha^w \delta_t \nabla_{\mathbf{w}} \hat{v}(S_t; \mathbf{w}_t).$$

Continuidad metodológica

Reconózcase aquí, intacto, el patrón de TD(0) de la Clase 3 y de SARSA de la Clase 4: el mismo δ_t que entonces actualizaba un valor, hoy gobierna simultáneamente al actor y al crítico. Nada de lo anterior queda atrás.

El actor-crítico como GPI diferenciable



El bucle de la Clase 4, redivivo

El **crítico** evalúa la política vigente mediante TD; el **actor** la mejora ascendiendo por el gradiente que el crítico pondera. Evaluación y mejora se entrelazan transición a transición.

Es, literalmente, la iteración de política generalizada de Howard, ahora dotada de aproximadores diferenciables que la proyectan a espacios continuos y de alta dimensión.

La función de ventaja y A2C

La ventaja mide cuánto supera una acción al promedio de su estado, y se anula en esperanza:

$$A_{\pi}(s, a) = q_{\pi}(s, a) - v_{\pi}(s), \quad \mathbb{E}_{A \sim \pi}[A_{\pi}(s, A)] = 0.$$

La línea base óptima es, en esencia, el propio valor de estado, $b^{\dagger}(s) = v_{\pi}(s)$. De allí que el error TD constituya un estimador insesgado de la ventaja, $\mathbb{E}[\delta_t \mid S_t = s, A_t = a] = A_{\pi}(s, a)$.

Conexión estadística

Es la lógica del *control variate*: restar una cantidad correlacionada y de esperanza conocida contrae la varianza sin perturbar el estimador. **A2C** (Advantage Actor-Critic) es exactamente este esquema.

Zhao (2024), §10.2 (invarianza y línea base óptima).

Estimación generalizada de la ventaja: GAE(λ)

¿Cuántos pasos antes de delegar en el crítico? Los estimadores de n pasos,

$$\hat{A}_t^{(n)} = \sum_{l=0}^{n-1} \gamma^l \delta_{t+l},$$

se promedia geométricamente en la *ventaja generalizada*:

$$\hat{A}_t^{\text{GAE}(\lambda)} = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l}.$$

El parámetro λ reaparece

Con $\lambda = 0$ recuperamos el estimador de un paso (sesgado, varianza mínima); con $\lambda = 1$, el de Monte Carlo (insesgado, varianza máxima). Es el compromiso de TD(λ) de la Clase 3, ahora al servicio de la ventaja.

Parte 3

Región de confianza y PPO

El problema del tamaño de paso

El gradiente de política es local; un paso excesivo puede degradar la política de forma abrupta, y como los datos son *on-policy*, una política dañada genera datos inservibles. La inestabilidad se realimenta.

Definamos la razón de probabilidades entre la política nueva y la que recogió los datos,

$$r_t(\boldsymbol{\theta}) = \frac{\pi_{\boldsymbol{\theta}}(A_t | S_t)}{\pi_{\boldsymbol{\theta}_{\text{old}}}(A_t | S_t)}, \quad L(\boldsymbol{\theta}) = \mathbb{E}_t[r_t(\boldsymbol{\theta}) \hat{A}_t].$$

El peligro

Maximizar $L(\boldsymbol{\theta})$ sin restricción alguna invita a pasos destructivos: la razón r_t puede dispararse y arrastrar la política lejos de la región donde la aproximación lineal es fiable.

Reaparece aquí el muestreo por importancia *off-policy* de la Clase 3.

TRPO: optimización con región de confianza

La optimización de región de confianza (TRPO) impide que la nueva política se aleje demasiado de la anterior, midiendo la distancia con la divergencia de Kullback–Leibler:

$$\max_{\theta} \mathbb{E}_t[r_t(\theta) \hat{A}_t] \quad \text{sujeto a} \quad \mathbb{E}_t[\text{KL}(\pi_{\theta_{\text{old}}} \parallel \pi_{\theta})] \leq \delta.$$

Garantía y costo

Bajo esta restricción se demuestra una mejora monótona aproximada. El precio es computacional: TRPO requiere productos Hessiano–vector y gradiente conjugado, lo que complica su uso a gran escala.

La pregunta que motivó a PPO fue directa: ¿puede capturarse el espíritu de la región de confianza con un objetivo de primer orden, optimizable con descenso estocástico ordinario?

PPO: el objetivo recortado

La respuesta de Proximal Policy Optimization es elegante en su economía. Sustituye la restricción dura por un recorte dentro del propio objetivo:

Objetivo sustituto recortado

$$L^{\text{CLIP}}(\boldsymbol{\theta}) = \mathbb{E}_t \left[\min(r_t(\boldsymbol{\theta}) \hat{A}_t, \text{clip}(r_t(\boldsymbol{\theta}), 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \right].$$

El operador clip confina la razón r_t al intervalo $[1 - \epsilon, 1 + \epsilon]$, y el min selecciona la alternativa *pesimista*. Así, el objetivo deja de premiar los desplazamientos que excedan la vecindad de confianza, suprimiendo de raíz el incentivo a alejarse en exceso.

El valor habitual $\epsilon = 0.2$ delimita una región de confianza implícita, sin Hessianos ni restricciones explícitas.

Schulman et al. (2017), *Proximal Policy Optimization Algorithms*.

Lectura geométrica del recorte

Ventaja positiva ($\hat{A}_t > 0$)

Conviene reforzar la acción, pero el recorte detiene el incentivo en $r_t = 1 + \epsilon$: más allá, el objetivo se aplanan y el gradiente se anula.

Ventaja negativa ($\hat{A}_t < 0$)

Conviene atenuar la acción, y el recorte limita la corrección en $r_t = 1 - \epsilon$, evitando colapsos abruptos de probabilidad.

Por qué PPO se volvió el caballo de batalla

Combina tres virtudes que rara vez coexisten: estabilidad cercana a la de una región de confianza, optimización de *primer orden* compatible con cualquier marco de diferenciación automática, e implementación de pocas líneas. Es el algoritmo de referencia en la práctica aplicada contemporánea.

Acciones continuas: políticas gaussianas

Cuanto se ha dicho vale, sin cambios, para espacios de acción continuos. Basta parametrizar una densidad —típicamente gaussiana— cuyos momentos sean salidas de la red:

$$\pi_{\theta}(a | s) = \mathcal{N}(a; \mu_{\theta}(s), \sigma_{\theta}^2(s)), \quad \nabla_{\theta} \log \pi_{\theta}(a | s) \text{ disponible en forma cerrada.}$$

Un puente hacia la familia continua

Cuando la política se fuerza a ser determinista, $a = \mu_{\theta}(s)$, se obtiene el *gradiente de política determinista* (DPG), núcleo de DDPG, TD3 y, con entropía, de Soft Actor-Critic. PPO, en cambio, conserva una política estocástica y trata de manera uniforme lo discreto y lo continuo.

Zhao (2024), §10.4 (gradiente determinista).

Parte 4

DQN avanzado: la familia *Rainbow*

Recordatorio: DQN y sus dos artificios

El DQN de la Clase 5 minimiza el error de Bellman cuadrático sobre transiciones muestreadas de una memoria de repetición $\mathcal{D}$:

$$\mathcal{L}(\mathbf{w}) = \mathbb{E}_{(s,a,r,s') \sim \mathcal{D}} \left[\left(r + \gamma \max_{a'} \hat{q}(s', a'; \mathbf{w}^-) - \hat{q}(s, a; \mathbf{w}) \right)^2 \right].$$

Repetición de experiencia

$\mathcal{D}$ rompe la correlación temporal de las muestras y reutiliza cada transición, mejorando la eficiencia.

Red objetivo

Los parámetros congelados $\mathbf{w}^-$ estabilizan el blanco *bootstrap*, atenuando la persecución de un objetivo móvil.

Sobre este andamiaje, una década de investigación apiló mejoras que hoy revisamos.

Double DQN: corregir el sesgo de maximización

El operador max sobre estimaciones ruidosas sobreestima sistemáticamente el valor: el mismo conjunto de estimaciones se usa para *seleccionar* y para *evaluar* la mejor acción. Double DQN desacopla ambas funciones:

$$y_t = R_{t+1} + \gamma \hat{q}(S_{t+1}, \arg \max_{a'} \hat{q}(S_{t+1}, a'; \mathbf{w}); \mathbf{w}^-).$$

Un viejo conocido

Reconózcase aquí el doble Q-Learning de la Clase 4 —ejemplo 6.7 de Sutton & Barto— trasladado al régimen profundo. El sesgo que entonces cuantificamos en un MDP de dos estados reaparece, y su corrección es idéntica en espíritu.

Repetición priorizada de la experiencia

No toda transición instruye por igual. La repetición priorizada muestrea cada experiencia con probabilidad creciente en la magnitud de su error TD:

$$\mathbb{P}(i) \propto p_i^\eta, \quad p_i = |\delta_i| + \varepsilon, \quad \eta \geq 0.$$

Una corrección necesaria

Muestrear de forma no uniforme introduce sesgo en la esperanza del gradiente. Se lo compensa con pesos de muestreo por importancia, $w_i = (N \mathbb{P}(i))^{-\beta}$, restituyendo la consistencia del estimador. El parámetro η interpola entre el muestreo uniforme ($\eta = 0$) y la priorización plena.

Schaul et al. (2016), *Prioritized Experience Replay*.

Dueling DQN: separar valor y ventaja

La arquitectura en duelo descompone la estimación en dos corrientes —el valor del estado y la ventaja de cada acción— que se recombinan con una normalización que garantiza identificabilidad:

$$\hat{q}(s, a) = \hat{v}(s) + \left(\hat{A}(s, a) - \frac{1}{|\mathcal{A}|} \sum_{a'} \hat{A}(s, a') \right).$$

Cuándo rinde

Resulta especialmente eficiente allí donde muchas acciones comparten valor: el agente aprende el valor del estado sin necesidad de estimar por separado cada acción casi equivalente. La función de ventaja del actor-crítico reaparece, ahora dentro de una red de valor.

Hacia *Rainbow*

Tres ingredientes adicionales completan el repertorio:

- **Retornos multipaso.** Blancos de n pasos que reequilibran sesgo y varianza —el espíritu de GAE en la rama de valor.
- **RL distribucional (C51).** Aprende la *distribución* completa del retorno, no solo su media; la información de orden superior afina la política.
- **Redes ruidosas.** Ruido paramétrico aprendible en los pesos: sustituye la exploración ϵ -voraz por una dirigida por la propia incertidumbre.

La síntesis

Rainbow integra los seis perfeccionamientos —Double, priorización, duelo, multipaso, distribucional y ruido— en un agente que alcanzó el estado del arte en Atari. Todo ello descansa, sin excepción, sobre el Q-Learning tabular de la Clase 4.

Parte 5

Ecosistema moderno: Gymnasium y Stable-Baselines3

Gymnasium: la interfaz estándar

Gymnasium —sucesor mantenido de OpenAI Gym— fija un contrato mínimo y uniforme entre agente y entorno:

```
obs, info = env.reset(seed);    obs, r, terminated, truncated, info = e
```

- **Espacios.** `Box` para magnitudes continuas, `Discrete` para acciones enumerables; describen formalmente $\mathcal{S}$ y $\mathcal{A}$.
- **Terminación frente a truncamiento.** La distinción —final genuino del episodio frente a corte por límite de tiempo— es crucial para no sesgar el blanco *bootstrap*.
- **Entornos vectorizados.** `SyncVectorEnv` y `AsyncVectorEnv` ejecutan múltiples copias en paralelo, alimentando con eficiencia a los métodos *on-policy*.

Stable-Baselines3: agentes listos para producción

Stable-Baselines3 ofrece implementaciones de referencia, verificadas y reproducibles, sobre PyTorch: DQN, A2C, PPO, SAC, TD3 y DDPG, tras una interfaz común.

El patrón de uso

```
from stable_baselines3 import PPO
model = PPO("MlpPolicy", env, seed=42, verbose=1)
model.learn(total_timesteps=300_000)
accion, _ = model.predict(obs, deterministic=True)
```

A ello se suman *callbacks* —en particular `EvalCallback` para evaluación periódica—, registro en TensorBoard y `VecNormalize` para la normalización de observaciones y recompensas. La complejidad algorítmica queda encapsulada; la atención del practicante se reorienta hacia el diseño experimental.

Anatomía de un experimento reproducible

La herramienta no exime del rigor; lo desplaza. Un estudio serio exige:

- Control de la aleatoriedad. Semillas fijadas en entorno y marco de cómputo, documentadas y reportadas.
- Réplicas múltiples. Varias corridas independientes; la curva de una sola siembra no es evidencia.
- Evaluación determinista periódica. Separada del entrenamiento, sobre episodios de prueba.
- Resumen honesto. Media y **desviación estándar insesgada** ($\text{ddof} = 1$), con coherencia explícita entre conclusiones y evidencia.

El sello del curso

El criterio estadístico exigido desde la Clase 3 gobierna aquí la comparación entre algoritmos profundos: la sofisticación del método no rebaja el estándar de la inferencia.

La práctica de hoy: LunarLander

Abandonamos CartPole por un escenario más rico y visualmente elocuente.

- **Entorno. LunarLander-v3:** estado continuo de ocho dimensiones, cuatro acciones discretas, recompensa conformada y umbral de resolución en 200.
- **Comparativa de familias.** Por el lado del valor, DQN frente a Double y Dueling; por el de la política, A2C frente a PPO, sobre el mismo entorno.
- **Estudios dirigidos.** Barrido del recorte $\epsilon \in \{0.1, 0.2, 0.3\}$ y de λ de GAE, prolongando el análisis de varianza de la Clase 5.
- **Cierre visual.** Grabación del agente: de una política aleatoria que se estrella al agente experto que aterriza con suavidad.

Cuaderno doble

Python alberga el núcleo numérico; R orquesta vía `reticulate` y visualiza con `ggplot2`. Ambos compatibles con Google Colab.

Parte 6

Aplicaciones contemporáneas y desafíos

El linaje AlphaGo → AlphaZero → MuZero

- AlphaGo (2016). Combinó redes de política y de valor con búsqueda de árbol Monte Carlo, inicializadas con partidas humanas. Venció al campeón mundial de Go, hito que se creía lejano.
- AlphaZero (2017). Prescindió por completo del conocimiento humano: *self-play* puro y una sola arquitectura dominando Go, ajedrez y shogi.
- MuZero (2020). Aprendió un modelo latente de la dinámica y planificó *sin conocer las reglas* del juego, fundiendo aprendizaje y planificación.

La frontera híbrida

Esta estirpe materializa el algoritmo que combina los tres ejes de la Clase 3 —muestreo, *bootstrapping* y modelo—: rollouts Monte Carlo, valor aproximado por red y, en MuZero, un modelo aprendido.

RLHF: PPO en los grandes modelos de lenguaje

El ajuste por retroalimentación humana es hoy la aplicación más masiva del gradiente de política, en dos fases:

1. Un **modelo de recompensa** $r_\phi(x, y)$ se entrena sobre comparaciones humanas, bajo un modelo de preferencias de Bradley–Terry.
2. **PPO** ajusta la política —el modelo de lenguaje— maximizando esa recompensa, con penalización KL respecto del modelo base:

$$\max_{\theta} \mathbb{E}[r_\phi(x, y)] - \beta \text{KL}(\pi_\theta \parallel \pi_{\text{base}}) .$$

Relevancia para un auditorio estadístico

El modelo de recompensa es aprendizaje de preferencias; la penalización KL, una regularización hacia un prior. PPO —que dedujimos hace minutos— es el puente entre el RL y los modelos de lenguaje de 2026.

Robótica, control, recomendación y finanzas

- Robótica y control. Locomoción y manipulación aprendidas en simulación y transferidas al mundo físico; el desafío *sim-to-real* y la brecha de realidad.
- Sistemas de recomendación. Emparentados con los *bandits* de la Clase 2: la tensión exploración–explotación gobierna qué contenido ofrecer en producción.
- Finanzas cuantitativas. Ejecución óptima de órdenes y gestión de carteras, siempre bajo la advertencia de la no estacionariedad de los mercados.

Una cautela metodológica

En dominios de alto riesgo —medicina, finanzas, política pública— la evaluación *off-policy* y la imposibilidad de experimentar libremente convierten la prudencia estadística en obligación, no en virtud opcional.

Desafíos abiertos

El campo dista de estar resuelto. Sus fronteras vivas merecen mención explícita:

- **Eficiencia muestral.** El RL profundo consume cantidades ingentes de experiencia; reducir esa demanda es central.
- **Seguridad y especificación.** Una recompensa mal diseñada invita al *reward hacking*: el agente optimiza la letra y traiciona el espíritu.
- **Interpretabilidad.** Comprender *por qué* una política decide lo que decide sigue siendo arduo.
- **Transferencia y generalización.** Llevar lo aprendido de una tarea a otra, y de la simulación a la realidad.
- **Reproducibilidad.** La sensibilidad a semillas e hiperparámetros exige el rigor experimental que hemos cultivado.

Parte 7

Integración: el mapa del curso

Seis encuentros, un principio: GPI

Si una sola idea hubiera de sobrevivir al curso, sería esta: **todo método de control es iteración de política generalizada**. Evaluar y mejorar, en cualquier proporción, desde la programación dinámica exacta hasta el RL profundo.

El objeto unificador

Y si un solo objeto matemático condensara esa idea, sería el error de diferencia temporal

$$\delta_t = R_{t+1} + \gamma \hat{v}(S_{t+1}) - \hat{v}(S_t).$$

Lo encontramos en TD(0), en SARSA, en Q-Learning, en el crítico del actor-crítico y, transformado en ventaja, en A2C y PPO. Reconocerlo a primera vista —como anticipé en la Clase 3— ahorra trabajo de descifrado ante cualquier artículo del campo.

La taxonomía del campo

Método	Qué aprende	On/Off	Clase
SARSA	$q(s, a)$	On	4
Q-Learning / DQN	$q(s, a)$	Off	4–5
REINFORCE	$\pi(a s)$	On	5
A2C	$\pi(a s), v(s)$	On	6
TRPO / PPO	$\pi(a s), A(s, a)$	On	6
DDPG / SAC	$\pi(a s), q(s, a)$	Off	6*

Tres preguntas bastan: ¿qué función aprende? ¿muestrea o modela? ¿hace *bootstrapping*?

*mencionado.

Puentes con la estadística y el control óptimo

El aprendizaje por refuerzo no es una isla; conversa de continuo con disciplinas que el auditorio domina.

- Robbins–Monro $\leftrightarrow$ Bellman. Todo método libre de modelo es aproximación estocástica aplicada a operadores de Bellman (Clase 3).
- Línea base y ventaja $\leftrightarrow$ control variates. Reducción de varianza por sustracción de cantidades correlacionadas.
- Sesgo–varianza $\leftrightarrow$ regularización. El eje MC–TD y el parámetro λ evocan ridge, estimadores de Stein y suavizado no paramétrico.
- RL $\leftrightarrow$ control óptimo aproximado. La programación dinámica aproximada de Bertsekas ofrece la lente de ingeniería de control sobre los mismos algoritmos.

Parte 8

Trabajo final integrador y consultas

El trabajo final integrador

El componente que corona la evaluación pondera el 50 % de la nota y sintetiza cuanto hemos construido.

Lo que debe contener

- Formulación del problema como proceso de decisión de Markov.
- Implementación documentada del algoritmo elegido.
- Análisis de resultados mediante gráficos y métricas pertinentes.
- Discusión honesta de limitaciones y de posibles extensiones.

El tema puede seleccionarse del catálogo propuesto o definirse de manera autónoma, con aprobación docente. Se admite todo el espectro recorrido: de un control tabular cuidadosamente analizado a un agente PPO sobre un entorno de Gymnasium.

Andamiaje con Stable-Baselines3

Para quienes opten por la vía profunda, el esqueleto mínimo es reproducible y conciso:

1. Elegir el entorno y formularlo como MDP; fijar la semilla.
2. Entrenar con PPO o DQN sobre Gymnasium mediante SB3.
3. Registrar curvas de aprendizaje sobre varias réplicas; reportar media y desviación insesgada.
4. Grabar el comportamiento del agente *antes* y *después* del entrenamiento.
5. Redactar el informe con discusión crítica.

Un consejo de cierre

El contraste visual entre la política aleatoria que fracasa y el agente final que resuelve el entorno convierte la entrega en un objeto elocuente. La evidencia bien presentada persuade más que cualquier afirmación.

Bibliografía de la Clase 6

- **Obligatoria.** Sutton & Barto (2018), cap. 13 completo, con énfasis en §13.4–13.6; Zhao (2024), caps. 9 y 10 (§10.2 ventaja, §10.4 gradiente determinista).
- **Recomendada.** Schulman et al. (2015, TRPO; 2016, GAE; 2017, PPO); van Hasselt et al. (2016, Double DQN); Wang et al. (2016, Dueling); Schaul et al. (2016, PER); Hessel et al. (2018, Rainbow).
- **Aplicaciones.** Silver et al. (2016, 2017); Schrittwieser et al. (2020, MuZero); Ouyang et al. (2022, RLHF); Sutton & Barto, cap. 16.
- **Complementaria.** Bertsekas, *Reinforcement Learning and Optimal Control*; Lapan; Graesser & Keng; Géron, para la práctica con SB3.

Palabras de cierre

Hemos recorrido, en seis encuentros, el arco que va del operador de Bellman a los algoritmos que hoy gobiernan agentes de juego, robots y modelos de lenguaje. Por debajo de la aparente diversidad late una sola arquitectura —evaluar y mejorar— y un puñado de ideas estadísticas que el auditorio ya conocía bajo otros nombres.

Lo que queda

Resta el trabajo final, donde cada cual hará propio un fragmento de este campo. El foro permanecerá abierto para las consultas; los animo a emplearlo, pues toda buena pregunta beneficia al conjunto.

Gracias por el recorrido compartido.